



UCAV

www.ucavila.es

UNIVERSIDAD CATÓLICA DE ÁVILA

FACULTAD DE CIENCIAS Y ARTES

CONVOCATORIA
DE EVALUACIÓN

JUNIO (Conv. Ordinaria)

CURSO
ACADÉMICO

2025/2026

TRABAJO FIN DE GRADO

Correspondiente a la titulación de

GRADO EN BIOINFORMÁTICA

Título del Trabajo Fin de Grado

Estudio de asociación del transcriptoma completo y análisis integrativo en corteza prefrontal para depresión mayor, trastorno bipolar y tentativa de suicidio

ESTUDIANTE: MIGUEL ROSELL HIDALGO

DIRECTOR/A: RUBÉN VILLA MUÑOZ

AGRADECIMIENTOS

A mi tutor Rubén, que ha tenido la bondad y la paciencia de adaptarse a mis ritmos, que ha sabido guiarme y cuestionar cada detalle, incluso en los ámbitos biológicos que en calidad de matemático no tiene por qué conocer. Gracias por tu rigor, pero sobre todo por tu amabilidad, Rubén, que es el recuerdo más valioso que atesoro conmigo.

Al Centro de Biología Molecular Severo Ochoa (CBMSO), en concreto al grupo de Aproximaciones Genómicas en Enfermedades Psiquiátricas, dirigido por el Dr. Claudio Toma, por permitir acceder a unos datos de alta calidad para la elaboración de mi Trabajo de Fin de Grado y guiarme en todo el proceso.

A Pablo, que me impulsa a ser mejor persona cada día, que aguanta todos mis despistes y me acompaña en todas mis desgracias y fortunas. Eres hogar, eres refugio y eres mi familia, y también la razón por la cual yo soy quien soy hoy. Y, que conste, que me caigo bien.

A mi psicóloga, Paloma. Gracias a ti he aprendido a ahorrarme batallas que antes decidía luchar, y guerras que nunca tuvo sentido enfrentar. Por enseñarme a que puedo confiar en mí, a que puedo permitirme doblegarme y llorar, y a darme cuenta de que yo estoy siempre conmigo.

A mis amigos del grado, Mireia, Sammy, Dan y un largo etcétera, por haber hecho este camino tan sumamente divertido, interesante y repetible. Sois una familia para mí, ¡y esto ha sido solo el comienzo!

A Rosa, Chema, Silvia y Lolo, porque sin su comida y cena preparada religiosamente cada día, ¿cuándo hago yo el TFG? Gracias por ser un refugio y una familia amorosa de manera constante, especialmente cuando más la necesitaba. Os llevo siempre en mi corazón.

Este TFG no es exclusivamente producto de mi trabajo, es el producto del trabajo que he podido realizar gracias a todos vosotros y, sin vosotros, tampoco hay TFG. Gracias, gracias, gracias.

«...aguarda y aguarda más aún. Quédate quieta, en silencio, y escucha a tu corazón. Y cuando te hable, levántate y ve donde él te lleve.»

— Susanna Tamaro, *Donde el corazón te lleve*

RESUMEN

Los trastornos psiquiátricos severos, como el trastorno depresivo mayor (MDD) y el trastorno bipolar (BD), así como fenotipos conductuales complejos como la tentativa de suicidio (SA), poseen una arquitectura genética de alta poligenicidad. Si bien los estudios de asociación del genoma completo (GWAS) han logrado mapear cientos de variantes de riesgo, la traslación de estas señales estadísticas a mecanismos patogénicos subyacentes sigue siendo uno de los mayores desafíos de la neurogenómica actual. Superando las limitaciones de los análisis de expresión diferencial fáctica — los cuales se encuentran frecuentemente sesgados por factores ambientales, por el estado clínico o por medicación—, el presente Trabajo de Fin de Grado implementa un estudio de asociación del transcriptoma completo (TWAS) para investigar exclusivamente el impacto de la **expresión génica heredable e inercial**.

Utilizando el panel de referencia transcriptómica de la corteza prefrontal dorsolateral (DLPFC) generado por el consorcio CommonMind, se integraron estadísticas de resumen procedentes de cohortes clínicas independientes para imputar la expresión cerebral de más de 5300 modelos génicos. Los *loci* priorizados ($P < 0.001$) se sometieron a un análisis conjunto y condicional (*joint/conditional tests*), que evaluó si sus señales eran independientes o redundantes por desequilibrio de ligamiento (LD); en los tres fenotipos todos los candidatos resultaron señales espacialmente independientes, sin que ninguno fuera descartado por LD. Posteriormente, las firmas genéticas primarias se sometieron a un análisis de sobrerrepresentación funcional (ORA) empleando las ontologías GO y KEGG.

El análisis funcional sugirió, con carácter exploratorio, perfiles biológicos diferenciados para cada fenotipo. En MDD, las firmas sugestivas señalaron, de forma exploratoria, alteraciones en la adhesión celular dependiente de calcio y en cascadas de señalización metabólica (insulina y mTOR); el análisis condicional confirmó que los tres genes priorizados (*QSOX1*, *PPMIJ* y *RAB17*) constituyen señales transcripcionales independientes. Por su parte, en BD, los seis genes priorizados (entre ellos *LOC728323*, *PARK7* y *SLMO1*) resultaron en señales independientes. Por último, en la conducta suicida, se mostró que los siete genes sugestivos (entre ellos *POLI*, *ANKRD18A* y *CD93*) constituyen señales transcripcionales independientes. El escrutinio funcional de las firmas asociadas a SA apuntó, con carácter exploratorio, a procesos de autofagia y a vías de respuesta al estrés genotóxico, como la reparación del ADN mediada por la vía de la Anemia de Fanconi.

En conjunto, este estudio explora si la predisposición genética constitutiva para alterar los niveles de transcripción en la corteza prefrontal podría llegar a conferir un riesgo inherente y rastreable para el desarrollo de trastornos psiquiátricos. Los hallazgos proporcionan un catálogo priorizado de genes candidatos y redes biológicas que constituyen un punto de partida para futuras validaciones funcionales, abriendo nuevas vías para la comprensión neurobiológica y la identificación de dianas terapéuticas.

Palabras clave: TWAS, bioinformática, trastorno depresivo mayor, trastorno bipolar, tentativa de suicidio, expresión génica predictiva, análisis condicional, DLPFC.

ABSTRACT

Severe psychiatric disorders, such as major depressive disorder (MDD) and bipolar disorder (BD), as well as complex behavioral phenotypes such as suicide attempt (SA), have a highly polygenic genetic architecture. Although genome-wide association studies (GWAS) have mapped hundreds of risk variants, translating these statistical signals into the underlying pathogenic mechanisms remains one of the greatest challenges in current neurogenomics. Overcoming the limitations of observed differential-expression analyses—which are frequently biased by environmental factors, clinical state, or medication—this Bachelor's Thesis implements a transcriptome-wide association study (TWAS) to investigate exclusively the impact of the heritable, constitutive component of gene expression.

Using the dorsolateral prefrontal cortex (DLPFC) transcriptomic reference panel generated by the CommonMind Consortium, summary statistics from independent clinical cohorts were integrated to impute brain expression for more than 5300 gene models. The prioritized *loci* ($P < 0.001$) were subjected to a joint and conditional analysis (joint/conditional tests), which assessed whether their signals were independent or redundant owing to linkage disequilibrium (LD); in all three phenotypes, every candidate proved to be a spatially independent signal, with none discarded owing to LD. The primary genetic signatures were then subjected to a functional over-representation analysis (ORA) using the GO and KEGG ontologies.

The functional analysis suggested, on an exploratory basis, distinct biological profiles for each phenotype in prefrontal tissue. In MDD, the suggestive signatures pointed, exploratorily, to alterations in calcium-dependent cell adhesion and in metabolic signaling cascades (insulin and mTOR); the conditional analysis confirmed that the three prioritized genes (*QSOX1*, *PPM1J*, and *RAB17*) constitute independent transcriptional signals. In BD, the six prioritized genes (including *LOC728323*, *PARK7*, and *SLMO1*) proved to be independent signals in the conditional analysis. Lastly, for suicidal behavior, seven suggestive genes (including *POLI*, *ANKRD18A*, and *CD93*) constituted independent transcriptional signals, with none discarded owing to linkage disequilibrium. The functional scrutiny of the SA-associated signatures pointed, on an exploratory basis, to autophagy processes and to genotoxic-stress response pathways, such as DNA repair mediated by the Fanconi anemia pathway.

Taken together, this study explores whether the constitutive genetic predisposition to alter transcription levels in the prefrontal cortex could confer an inherent and traceable risk for the development of psychiatric disorders. The findings provide a prioritized catalog of candidate genes and biological networks that constitute a starting point for future functional validation, opening new avenues for neurobiological understanding and the identification of therapeutic targets.

Keywords: TWAS, bioinformatics, major depressive disorder, bipolar disorder, suicide attempt, predicted gene expression, conditional analysis, DLPFC.

ÍNDICE GENERAL

RESUMEN	3
ABSTRACT	5
GLOSARIO DE TÉRMINOS	11
1. INTRODUCCIÓN	15
1.1. Delimitación clínica de los fenotipos de estudio	15
1.2. El comportamiento suicida como reto para la salud pública global.	15
1.3. El espectro clínico y el modelo de diátesis-estrés	16
1.4. Arquitectura genética y heredabilidad	17
1.5. Trastorno depresivo mayor y trastorno bipolar: carga global y comorbilidad	18
1.6. Convergencia genética y la limitación funcional	18
2. JUSTIFICACIÓN	20
2.1. La importancia de trascender la genómica descriptiva	20
2.2. Motivación tras el método TWAS y la eliminación de barreras analíticas	21
2.3. La corteza prefrontal dorsolateral como tejido fundamental: Relevancia del tejido diana	22
2.4. Impacto anticipado y aplicaciones clínicas futuras	22
3. OBJETIVOS	24
3.1. Objetivo general	24
3.2. Objetivos específicos	24
4. MARCO TEÓRICO	26
4.1. Arquitectura genética y regulación transcripcional en psiquiatría	26
4.2. Fundamentos computacionales de la imputación transcriptómica (TWAS)	27
4.3. Desentrañando la señal: desequilibrio de ligamiento y redes funcionales	28
5. METODOLOGÍA	30
5.1. Origen de los datos	30
5.1.1. Estructura computacional relacionada con los datos de origen	31
5.2. Control de calidad (QC) y preprocesamiento computacional	33
5.2.1. Limpieza de datos faltantes (NAs)	34
5.2.2. Cálculo del estadístico Z (Z-score)	34
5.2.3. Generación del archivo de entrada	35
5.3. Preparación del entorno informático y recursos genómicos	36
5.3.1. Instalación en R y dependencias críticas	37
5.3.2. Descarga y configuración sobre el ecosistema FUSION	37
5.3.3. Modelos sobre expresión transcriptómica (los pesos del modelo)	38
5.3.4. Fundamentos matemáticos del modelo TWAS: desequilibrio de ligamiento (LD) y varianza combinada	
39	
5.3.4.1. El desequilibrio de ligamiento (LD) como matriz de correlación	39

5.3.4.2.	Modelado mediante álgebra lineal y pesos de expresión.....	39
5.3.4.3.	Corrección por redundancia y varianza combinada.....	40
5.4.	Realización del análisis de asociación transcriptómica (TWAS)	41
5.4.1.	Validación del pipeline con el cromosoma 22	42
5.4.2.	Análisis con el genoma completo (cromosomas 1-22).....	42
5.4.3.	Exclusión de genes y manejo de la región MHC	43
5.5.	Interpretación analítica de la salida de datos	44
5.6.	Análisis estadístico y visualización a escala genómica	47
5.6.1.	Corrección por pruebas múltiples (Umbral de Bonferroni).....	48
5.6.2.	Análisis estadístico con visualización mediante Manhattan Plot	48
5.6.3.	Extracción desde <i>loci</i> sugerentes para revisión biológica	50
5.7.	Guía de interpretación de hallazgos.....	52
5.8.	Análisis condicional de TWAS y conjunto de señales	53
5.9.	Análisis de enriquecimiento funcional y vías biológicas	56
6.	RESULTADOS	58
6.1.	Obtención de resultados de los análisis	58
6.1.1.	Resultados primarios del análisis de asociación transcriptómica (TWAS).....	59
6.1.1.1.	Evaluación global a nivel de transcriptoma y control de multiplicidad	59
6.1.1.2.	<i>Loci</i> sugestivos identificados por fenotipo clínico.....	60
6.1.2.	Resultados completos del análisis conjunto condicional	65
6.1.2.1.	Resultados del análisis conjunto y condicional para la depresión mayor (MDD)	66
6.1.2.2.	Resultados del análisis conjunto y condicional para el trastorno bipolar (BD) en la corteza prefrontal dorsolateral (DLPFC)	69
6.1.2.3.	Resultados del análisis conjunto y condicional para tentativa de suicidio (SA) en corteza prefrontal dorsolateral (DLPFC)	74
6.1.3.	Resultados del enriquecimiento funcional	79
6.1.3.1.	Trastorno depresivo mayor	79
6.1.3.2.	Trastorno bipolar	81
6.1.3.3.	Tentativa de suicidio	83
7.	CONCLUSIONES.....	85
7.1.	Sobre el objetivo metodológico: la viabilidad del <i>pipeline</i> y la fortaleza del enfoque transcriptómico hereditario	85
7.2.	Sobre el objetivo primario del TWAS: identificación de <i>loci</i> con asociación sugestiva.....	86
7.3.	Sobre el análisis condicional: independencia de las señales sugestivas	87
7.4.	Sobre el enriquecimiento funcional: convergencia biológica y rutas de señalización relevantes	88
7.5.	Limitaciones del estudio.....	90
7.6.	Conclusión general	91
8.	PROSPECTIVA FUTURA	92
8.1.	Validación experimental funcional (<i>in vitro</i> e <i>in vivo</i>)	92
8.2.	Expansión de la resolución anatómica y unicelular.....	93
8.3.	Integración multi-ómica a nivel de sistemas	93
8.4.	Aumento de la potencia estadística y diversidad ancestral	94

8.5. Traslación farmacogenómica y psiquiatría de precisión	94
BIBLIOGRAFÍA	96
ANEXOS	102
9. ANEXO I. Protocolos computacionales y <i>scripts</i> de procesamiento de datos en R	102
9.1. Código I.1. Preprocesamiento de estadísticas de resumen y cálculo de <i>Z-scores</i>	102
9.2. Código I.2. Procesamiento estadístico post-TWAS, ajuste por comparaciones múltiples y generación de Manhattan Plot	102
9.3. Código I.3. Filtrado y sanitización de datos para análisis condicional. Ejemplo de filtrado_condicional_mdd	105
9.4. Código I.4. Extracción de <i>loci</i> candidatos para análisis de enriquecimiento funcional. Ejemplo limpiar_resultados_enriquecimiento_bd.R	105

ÍNDICE DE FIGURAS

Figura 1. Modelos de expresión génica de tejido único disponibles en el repositorio de FUSION.....	38
Figura 2. Ejemplo representativo de un Manhattan plot en un estudio TWAS.	49
Figura 3. Gráfico de Manhattan de las asociaciones transcriptómicas para el trastorno depresivo mayor...	61
Figura 4. Gráfico de Manhattan de las asociaciones transcriptómicas para el trastorno bipolar.	62
Figura 5. Gráfico de Manhattan de las asociaciones transcriptómicas para la tentativa de suicidio.	64
Figura 6. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen QSOX1 en el contexto de la depresión mayor.....	67
Figura 7. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen PPM1J en MDD.	68
Figura 8. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen RAB17 en MDD.	69
Figura 9. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen FAM21C (cromosoma 10) en el trastorno bipolar.....	70
Figura 10. Gráfico LocusZoom condicional para el locus del gen PCGF3 (cromosoma 4) en el trastorno bipolar.....	71
Figura 11. Gráfico LocusZoom condicional para el locus de LOC728323 (cromosoma 2) en el trastorno bipolar.....	71
Figura 12. Gráfico LocusZoom condicional para el locus del gen PARK7 (cromosoma 1) en el trastorno bipolar.....	72
Figura 13. Gráfico LocusZoom condicional para el locus del gen CRB1 (cromosoma 1) en el trastorno bipolar.	73
Figura 14. Gráfico LocusZoom condicional para el locus del gen SLMO1 (cromosoma 18) en el trastorno bipolar.....	74
Figura 15. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen ESR1 (cromosoma 6) en tentativa de suicidio.	75
Figura 16. Gráfico LocusZoom condicional para el locus del gen ABCB8 (cromosoma 7) en SA.....	76
Figura 17. Gráfico LocusZoom condicional para el locus del gen QSOX1 (cromosoma 1) en SA.	76
Figura 18. Gráfico LocusZoom condicional para el locus del gen RSU1 (cromosoma 10) en SA.....	77
Figura 19. Gráfico LocusZoom condicional para el locus del gen POLI (cromosoma 18) en la tentativa de suicidio.....	77
Figura 20. Gráfico LocusZoom condicional para el locus del gen ANKRD18A (cromosoma 9) en SA.	78
Figura 21. Gráfico LocusZoom condicional para el locus del gen CD93 (cromosoma 20) en SA.....	78
Figura 22. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos en el trastorno depresivo mayor.....	80
Figura 23. Gráfico de barras de rutas de señalización (KEGG Human Pathways) enriquecidas en el trastorno depresivo mayor.....	81
Figura 24. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos en el trastorno bipolar.....	82
Figura 25. Gráfico de barras de rutas moleculares (KEGG Human Pathways) enriquecidas en el trastorno bipolar.....	83
Figura 26. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos para el fenotipo de tentativa de suicidio.	83
Figura 27. Gráfico de barras de rutas metabólicas y de reparación (KEGG Human Pathways) enriquecidas para el fenotipo de tentativa de suicidio.	84

INDICE DE TABLAS

Tabla 1. Asociaciones transcriptómicas sugestivas para el trastorno depresivo mayor (MDD).	61
Tabla 2. Asociaciones transcriptómicas sugestivas para el trastorno bipolar (BD).....	62
Tabla 3. Asociaciones transcriptómicas sugestivas para la tentativa de suicidio (SA).	63
Tabla 4. Resultados del análisis conjunto y condicional (joint/conditional test de FUSION) para los genes sugestivos de los tres fenotipos (MDD, BD y SA).	65

GLOSARIO DE TÉRMINOS

Término / Acrónimo	Descripción
BD	<i>(Bipolar Disorder)</i> . Trastorno bipolar. Enfermedad mental caracterizada por fluctuaciones extremas del estado de ánimo, que incluyen episodios maníacos (o hipomaníacos) y depresivos.
CRAN	<i>(Comprehensive R Archive Network)</i> . Sistema de repositorios que funciona a nivel mundial, con el objetivo de almacenar y distribuir paquetes de software junto con documentación verificada destinada para el lenguaje estadístico R.

Término / Acrónimo	Descripción
FUSION	Es una herramienta informática que ha sido desarrollada para llevar a cabo el análisis TWAS. Integra modelos predictivos de expresión y estadísticas de resumen provenientes de un GWAS. (Gusev et al., 2016)
GWAS	(<i>Genome-Wide Association Study</i>). Estudio de asociación del genoma completo que explora cientos de miles de variantes genéticas relevantes para identificar <i>loci</i> asociados a un rasgo o enfermedad.
Locus (plural: loci)	La posición física y constante en un cromosoma de un gen, un polimorfismo o de una secuencia de ADN.
MDD	(<i>Major Depressive Disorder</i>). Trastorno depresivo mayor. Trastorno de salud mental caracterizado por un estado de ánimo deprimido persistente, pérdida de interés en las actividades y deterioro cognitivo o físico.

Término / Acrónimo	Descripción
Regulación en cis (eQTL cis)	Variante genética que regula o controla el nivel de expresión de un gen diana que se encuentra físicamente cerca de ella en el mismo cromosoma (convencionalmente, a menos de una megabase de distancia).
Regulación en trans (eQTL trans):	Variante genética que altera la expresión de un gen diana ubicado a gran distancia, ya sea en una región muy alejada del mismo cromosoma o en un cromosoma completamente distinto, habitualmente alterando factores de transcripción intermediarios.
TWAS	<i>(Transcriptome-Wide Association Study)</i> . Metodología que evalúa la asociación entre la expresión génica (generalmente imputada o predicha genéticamente) y un fenotipo de gran interés. (Gusev et al., 2016)
SA	<i>(Suicide Attempt)</i> . Tentativa de suicidio. Comportamiento potencialmente lesivo y autoinfligido, con una intención de morir que no resulta en la muerte.

Término / Acrónimo	Descripción
SNP	<i>(Single Nucleotide Polymorphism)</i> . Polimorfismo de nucleótido único: la variación de un solo par de bases en la secuencia de ADN.

1. INTRODUCCIÓN

1.1. DELIMITACIÓN CLÍNICA DE LOS FENOTIPOS DE ESTUDIO

La delimitación fenotípica de las condiciones analizadas en este estudio se fundamenta en los criterios clínicos estandarizados a nivel internacional. El trastorno depresivo mayor (MDD) es una patología psiquiátrica severa caracterizada por la presencia de uno o más episodios depresivos, definidos por un estado de ánimo deprimido persistente o una anhedonia (pérdida de interés o de la capacidad para sentir placer) marcada, acompañados de alteraciones cognitivas, psicomotoras y neurovegetativas que causan un deterioro clínicamente significativo en el funcionamiento psicosocial del individuo ([Asociación Americana de Psiquiatría \[APA\], 2023](#)). Por su parte, el trastorno bipolar (BD) se conceptúa como un trastorno crónico y episódico cuya característica patognomónica es la ocurrencia de al menos un episodio maníaco o hipomaníaco; estados de ánimo anormal y persistentemente elevados, expansivos o irritables, con un aumento patológico de la energía y de la actividad dirigida a un objetivo, los cuales frecuentemente se alternan con episodios depresivos mayores ([Organización Mundial de la Salud \[OMS\], 2022](#)). Finalmente, la tentativa de suicidio (SA) representa un fenotipo conductual agudo que se define clínicamente como un comportamiento autoinfligido, no fatal y potencialmente lesivo, acompañado de evidencia explícita o implícita de intencionalidad de morir como resultado de dicho acto, independientemente de si el comportamiento desemboca en lesiones o daño médico real ([APA, 2023](#)).

1.2. EL COMPORTAMIENTO SUICIDA COMO RETO PARA LA SALUD PÚBLICA GLOBAL.

En el presente, la conducta suicida es uno de los retos más apremiantes y complejos para la salud pública a escala global. La Organización Mundial de la Salud estima que cada año mueren por suicidio más de 700 000 personas, lo que lo convierte en una de las tasas principales de mortalidad

prematura, especialmente en jóvenes. Sin embargo, las cifras de mortalidad reflejan una parte de la magnitud del problema: para cada suicidio consumado, se calcula que ocurren aproximadamente veinte intentos de suicidio no fatales. ([OMS, 2021](#)).

Este fenómeno conlleva, además de una elevada pérdida de vidas humanas y un profundo impacto psicológico en los entornos familiares, una inmensa carga asistencial para los sistemas sanitarios. Se han desarrollado diversas estrategias de prevención psicosocial, pero las tasas globales de suicidio no han tenido una reducción drástica y sostenida en las décadas recientes. Esto evidencia la necesidad de profundizar en los mecanismos biológicos subyacentes con el fin de desarrollar herramientas de prevención más precisas ([OMS, 2021](#)).

1.3. EL ESPECTRO CLÍNICO Y EL MODELO DE DIÁTESIS-ESTRÉS

El comportamiento suicida no debe entenderse como un evento aislado, sino como un espectro clínico continuo que abarca desde la ideación suicida pasiva, la planificación y la tentativa, hasta el suicidio consumado. Dentro de este continuo, la tentativa de suicidio se ha establecido sistemáticamente en la literatura clínica como el factor de riesgo predictor más potente para un futuro suicidio ([Bostwick et al., 2016](#)).

La etiología de la conducta suicida tradicionalmente se ha conceptualizado por medio del modelo de diátesis-estrés. Este paradigma postula que los episodios suicidas surgen de la interacción entre estresores ambientales precipitantes; por ejemplo, traumas infantiles, eventos vitales adversos o factores socioeconómicos. Dicha interacción ocurre con una vulnerabilidad intrínseca o predisposición biológica, también conocida como diátesis ([Turecki et al., 2019](#)). Tradicionalmente, esta vulnerabilidad se atribuía casi de manera exclusiva a la presencia de trastornos psiquiátricos comórbidos, especialmente la depresión mayor, el trastorno bipolar o la esquizofrenia. Sin embargo,

la evidencia científica hoy sugiere que, aunque los trastornos psiquiátricos son catalizadores potentes, podría existir un componente independiente, neurobiológico y genético, que predispone a individuos a la conducta suicida *per se* ([Sokolowski y Wasserman, 2021](#)).

1.4. ARQUITECTURA GENÉTICA Y HEREDABILIDAD

La hipótesis sobre una vulnerabilidad biológica independiente se apoya de forma robusta en la investigación dentro de la genética psiquiátrica. Varios estudios epidemiológicos, que incluyen cohortes de gemelos y registros de adopciones, han evidenciado que el comportamiento suicida consta de una agregación familiar significativa. Los metaanálisis a gran escala más recientes, liderados por el Psychiatric Genomics Consortium (PGC), confirman esta arquitectura genética poligénica y sitúan la heredabilidad de la tentativa de suicidio en un rango aproximado del 30 % al 55 % según estudios de gemelos, además de alrededor de un 5.7 % para la heredabilidad basada en variantes comunes (SNPs) a nivel genómico ([Mullins et al., 2022](#); [Docherty et al., 2023](#)).

Esta carga hereditaria indica que la variación de la secuencia del ADN juega un papel fundamental en la susceptibilidad individual.

En años recientes, el desarrollo de los estudios de asociación de genoma completo (GWAS) ha dado pie a explorar esta arquitectura genética a gran escala. Estos estudios han respaldado la tentativa de suicidio como un rasgo altamente poligénico, regido mediante la suma de miles de variantes genéticas de efecto pequeño (polimorfismos de nucleótido único o SNPs) y distribuidas por el genoma completo.

1.5. TRASTORNO DEPRESIVO MAYOR Y TRASTORNO BIPOLAR: CARGA GLOBAL Y COMORBILIDAD

Aunque la tentativa de suicidio posee una base genética independiente, resulta imperativo contextualizarla dentro del espectro de los trastornos psiquiátricos severos con los que frecuentemente coexiste. Entre ellos, el trastorno depresivo mayor y el trastorno bipolar destacan como los principales factores de riesgo clínico para la conducta suicida. Asimismo, destacan como dos de las patologías más incapacitantes en todo el mundo.

El trastorno depresivo mayor afecta a más de 280 millones de personas en el mundo. Este trastorno es catalogado por la Organización Mundial de la Salud como la principal causa global de discapacidad ([OMS, 2023](#)). Se caracteriza por episodios de tristeza profunda, anhedonia y deterioro cognitivo y posee una etiología compleja en la que la genética explica cerca de un 30-40 % de la varianza poblacional ([Otte et al., 2016](#)).

El trastorno bipolar, que se caracteriza por cambios del ánimo muy grandes entre manía (o hipomanía) y depresión severa, afecta a unos 40 millones de personas ([OMS, 2023](#)). A pesar de que su prevalencia poblacional es menor que la del MDD, el trastorno bipolar presenta una de las tasas de heredabilidad más altas dentro de la psiquiatría, superando frecuentemente el 70 % en estudios de gemelos, lo cual evidencia una determinación genómica ineludible ([Grande et al., 2016](#)).

1.6. CONVERGENCIA GENÉTICA Y LA LIMITACIÓN FUNCIONAL

El reciente desarrollo de consorcios internacionales de genómica psiquiátrica ha mostrado que estas condiciones, la tentativa de suicidio, la depresión mayor y el trastorno bipolar comparten una arquitectura genética subyacente significativa ([Cross-Disorder Group of the Psychiatric Genomics Consortium, 2019](#)). Los análisis de correlación genética demuestran una pleiotropía sustancial, es

decir, gran parte de las variantes genéticas (SNPs) que predisponen a sufrir un trastorno del estado de ánimo además elevan el riesgo de desarrollar conductas suicidas ([Anttila et al., 2018](#)).

No obstante, aunque los estudios GWAS han tenido éxito en la identificación de cientos de *loci* genómicos asociados a estas tres condiciones relevantes, la comunidad científica se enfrenta a un cuello de botella fundamental: la inmensa mayoría de estas mutaciones se encuentran en regiones no codificantes del ADN. Esto indica que las variantes de riesgo no alteran de manera directa la estructura de las proteínas. Sin embargo, actúan como elementos reguladores de la expresión génica, un postulado que es respaldado por análisis recientes. Estos análisis demuestran que cerca del 90 % de las variantes de riesgo genómico operan al alterar elementos reguladores transcripcionales ([Lu et al., 2023](#)).

Por tanto, el desafío actual no consiste como tal en localizar las variantes asociadas, pues los GWAS ya han identificado cientos, sino en descifrar qué genes regulan y a través de qué mecanismos funcionales ejercen su efecto.

2. JUSTIFICACIÓN

2.1. LA IMPORTANCIA DE TRASCENDER LA GENÓMICA DESCRIPTIVA.

El auge de los estudios de asociación de genoma completo (GWAS) ha implicado un progreso inédito en la psiquiatría genética y ha permitido identificar miles de variantes genéticas asociadas al comportamiento suicida, así como a los trastornos del estado de ánimo. No obstante, la investigación genómica actual hace frente a un obstáculo traslacional severo: se estima que más del 90 % de los polimorfismos de nucleótido único que los GWAS identifican están en zonas no codificantes del genoma ([Gallagher y Chen-Plotkin, 2018](#)). En la práctica biológica, esto quiere decir que casi todas las mutaciones asociadas a estos trastornos no cambian de manera directa la estructura física de las proteínas en sí. Más bien, actúan como interruptores que regulan cantidad hasta dónde se expresa un gen. Por consiguiente, para comprender bien el riesgo genético, la sola identificación de la variante resulta insuficiente; es necesario aplicar análisis de predicción transcriptómica (TWAS) que hagan posible traducir estas señales genómicas ciegas a alteraciones específicas de la expresión génica en el tejido cerebral.

Esto supone una dificultad interpretativa considerable. Estas variantes pueden ejercer funciones reguladoras sobre la expresión génica sin alterar directamente la secuencia aminoacídica de las proteínas. Por consiguiente, un GWAS por sí mismo resulta insuficiente para determinar con exactitud qué gen específico está siendo desregulado, en qué dirección (sea sobreexpresión o silenciamiento) y en qué tejido diana ocurre dicho fenómeno. La identificación de la variante estadística resulta únicamente el primer paso, pues el verdadero desafío biológico reside en esclarecer el mecanismo funcional subyacente.

2.2. MOTIVACIÓN TRAS EL MÉTODO TWAS Y LA ELIMINACIÓN DE BARRERAS ANALÍTICAS

Con el fin de superar la distancia entre la genética de poblaciones y la neurobiología funcional, la presente investigación toma la metodología de los estudios de asociación de transcriptoma completo (TWAS). Por medio del enfoque TWAS, se permite integrar datos empíricos de expresión génica (eQTLs) derivados de tejidos humanos reales. Esto es posible a partir de resultados de cohortes GWAS grandes, tal como señala Alexander Gusev en su estudio de enfoques integrativos para estudios TWAS a gran escala ([Gusev et al., 2016](#)).

La elección de esta metodología en concreto, llevada a cabo a través del software FUSION, se justifica por una optimización tanto de los recursos analíticos como del poder estadístico. Inicialmente, los modelos transcriptómicos predictivos requerían acceso a microdatos genómicos de nivel individual (genotipos sin procesar), lo cual plantea fuertes barreras éticas de privacidad, ya que la secuencia exacta de ADN es un dato de carácter personal altamente identificable. Su manejo exige la aprobación de comités éticos y el uso de servidores de alta seguridad para evitar la reidentificación de los participantes o la revelación de predisposiciones clínicas incidentales. Además, estas limitaciones logísticas y de coste computacional limitaban el tamaño muestral usualmente a solo cientos de individuos.

Este proyecto hace uso de un modelo matemático que soluciona esas limitaciones, ya que trabaja solo con resúmenes estadísticos (*summary statistics*). Este abordaje usa matrices sobre desequilibrio de ligamiento (LD), así como también técnicas de álgebra lineal. Calcular la varianza combinada nos permite inferir la expresión génica aprovechando el poder estadístico de la cohorte que supera los 4000 individuos para cada fenotipo (alcanzando, por ejemplo, los 5258 sujetos en el caso de la tentativa de suicidio), sin necesidad de acceder a sus genomas individuales ([Wainberg et](#)

[al., 2019](#)). Esta estrategia maximiza hasta la potencia estadística del estudio guardando un estricto rigor analítico.

2.3. LA CORTEZA PREFRONTAL DORSOLATERAL COMO TEJIDO FUNDAMENTAL: RELEVANCIA DEL TEJIDO DIANA.

La justificación biológica en relación con el modelo predictivo se fundamenta en la elección del tejido de referencia. La expresión de los genes varía bastante entre los tejidos del cuerpo. En este trabajo, los modelos con pesos de expresión génica (derivados de parte del consorcio CommonMind) corresponden en concreto a muestras de ARN secuenciado desde la corteza prefrontal dorsolateral humana ([Fromer et al., 2016](#)).

La elección de esta región cerebral no es arbitraria. Según la literatura neurocientífica, la corteza prefrontal resulta ser el principal sustrato neuroanatómico para las funciones ejecutivas, el control inhibitorio de los impulsos y la regulación de la reactividad emocional. Las disfunciones detectadas en estos circuitos cognitivos sí constituyen, en efecto, el eje fisiopatológico de la vulnerabilidad suicida, al igual que del trastorno depresivo mayor y del trastorno bipolar. El riesgo genético se proyecta hacia este tejido en específico. En este sentido, los hallazgos poseen plausibilidad neurobiológica alta para este fenotipo. ([Friedman y Robbins, 2022](#)).

2.4. IMPACTO ANTICIPADO Y APLICACIONES CLÍNICAS FUTURAS

En definitiva, este trabajo se justifica por la necesidad de arrojar luz sobre la etiología funcional del comportamiento suicida, el trastorno bipolar y la depresión mayor. Este estudio pretende contribuir en la comprensión del modelo de diátesis-estrés a nivel molecular y, a su vez, busca ayudar

en el señalamiento de biomarcadores potenciales, al identificar qué genes específicos ven alterada su expresión cerebral debido a la carga genética heredada.

La identificación de genes de riesgo transcriptómico a largo plazo puede facilitar la estratificación de los pacientes según su perfil de vulnerabilidad biológica, e incluso abrir la puerta a la investigación de nuevas dianas terapéuticas dirigidas a restaurar los niveles de expresión génica que se encuentran alterados en la corteza prefrontal (psicofarmacología de precisión) ([Gandal et al., 2018](#)).

3. OBJETIVOS

El presente Trabajo de Fin de Grado tiene como propósito principal caracterizar la arquitectura genética y funcional subyacente a tres fenotipos psiquiátricos complejos: el trastorno depresivo mayor (MDD), el trastorno bipolar (BD) y la tentativa de suicidio (SA), mediante la integración de datos genómicos a gran escala.

Para lograr este propósito, el estudio se estructura en torno a un objetivo general y una serie de objetivos específicos que guían el diseño metodológico.

3.1. OBJETIVO GENERAL

El objetivo central de esta investigación es determinar si la expresión génica imputada (el componente transcriptómico puramente hereditario e «inercial»), predicha de manera específica en el tejido de la corteza prefrontal dorsolateral (DLPFC), presenta una asociación estadísticamente significativa con la susceptibilidad de padecer los fenotipos estudiados.

Mediante este enfoque, el proyecto busca trascender las limitaciones de los análisis clásicos de expresión diferencial fáctica. Mientras que la expresión fáctica observable en un momento dado está fuertemente sesgada por factores ambientales, estado clínico o tratamientos farmacológicos, este estudio persigue responder a una pregunta biológica fundamental: *¿la predisposición genética constitutiva de un individuo para transcribir ciertos loci en su tejido cerebral confiere, por sí misma, un riesgo inherente para el desarrollo de trastornos psiquiátricos severos o conducta suicida?*

3.2. OBJETIVOS ESPECÍFICOS

Para dar respuesta al objetivo general y garantizar el rigor metodológico del análisis bioinformático, se plantean los siguientes objetivos específicos secuenciales:

- **Armonización y preprocesamiento de bases de datos genómicas:** Estandarizar las estadísticas de resumen (*summary statistics*) provenientes de estudios de asociación de genoma completo (GWAS) independientes para MDD, BD y SA. Esto incluye el filtrado de valores ausentes y de *Odds Ratios* no válidos, así como el cálculo de los estadísticos de asociación normalizados (*Z-scores*) requeridos para la inferencia transcriptómica.
- **Ejecución del análisis de asociación de transcriptoma completo (TWAS):** Integrar la señal de riesgo de las cohortes clínicas con los paneles de referencia de expresión génica humana del consorcio CommonMind. El fin es computar las predicciones transcriptómicas a escala genómica e identificar aquellos *loci* cuya expresión cerebral regulada genéticamente alcance niveles de asociación sugestiva con los fenotipos clínicos.
- **Depuración topológica mediante análisis condicional:** Evaluar la solidez estadística de los *loci* candidatos mediante pruebas de condicionamiento (*post-process joint/conditional tests*). Este paso tiene como objetivo discriminar las señales transcriptómicas biológicamente independientes y funcionalmente prioritarias (*putative drivers*) de aquellos falsos positivos impulsados puramente por artefactos de vecindad genómica o desequilibrio de ligamiento (LD).
- **Caracterización de redes y enriquecimiento funcional:** Trasladar los hallazgos de asociación estadística individual a un contexto biológico integral. Mediante el uso de métodos de sobrerrepresentación, también conocido como *over-representation analysis* (ORA) y la interrogación de bases de datos estandarizadas (GO Biological Process y KEGG Human Pathways), se busca identificar qué rutas metabólicas, procesos celulares y vías de señalización neurobiológica convergen en el riesgo poligénico de cada trastorno.

4. MARCO TEÓRICO

4.1. ARQUITECTURA GENÉTICA Y REGULACIÓN TRANSCRIPCIONAL EN PSIQUIATRÍA

Históricamente, la investigación sobre la genética de los trastornos psiquiátricos severos, como el trastorno depresivo mayor, el trastorno bipolar y la tentativa de suicidio, se ha llevado a cabo a través de estudios de asociación del genoma completo (GWAS). Estos estudios han demostrado que dichas patologías poseen una arquitectura genética altamente poligénica. En este sentido, miles de variantes de un solo nucleótido (SNPs) contribuyen al fenotipo con tamaños de efecto muy pequeños ([Howard et al., 2019](#); [Mullins et al., 2021](#)).

Los GWAS, sin embargo, presentan un desafío fundamental para la traducción biológica. Más del 90 % de las variantes genéticas asociadas a enfermedades psiquiátricas residen en regiones no codificantes del genoma. Esto sugiere que el mecanismo subyacente de la patogénesis no radica en la alteración estructural de proteínas, sino en la desregulación precisa de la expresión génica a través de elementos reguladores cis y trans ([Anttila et al., 2018](#)). En este contexto, adquieren una importancia crucial los *loci* de rasgos cuantitativos de expresión (eQTLs, por sus siglas en inglés), que son variantes genéticas que explican una parte de la varianza en los niveles de expresión de un gen.

En los trastornos del estado de ánimo, así como en el comportamiento suicida, la corteza prefrontal dorsolateral (DLPFC) ha emergido como un tejido cerebral objetivo. La DLPFC es un nodo crucial en las redes de control cognitivo junto con regulación emocional, y los estudios *post mortem* han evidenciado profundas alteraciones en su perfil transcriptómico en pacientes psiquiátricos ([Gandal et al., 2018](#)). Por consiguiente, la consolidación de datos genómicos junto a modelos de expresión específicos del DLPFC representa un paso que es a la vez lógico y necesario para desvelar los mecanismos etiológicos que subyacen a estos fenotipos.

4.2. FUNDAMENTOS COMPUTACIONALES DE LA IMPUTACIÓN TRANSCRIPTÓMICA (TWAS)

Para superar las limitaciones interpretativas de los GWAS, en los últimos años, como parte del avance en la genética, se ha desarrollado el análisis TWAS. A diferencia de los GWAS, que evalúan la asociación marginal de cada SNP de forma independiente, el TWAS evalúa la conexión entre un rasgo complejo y la expresión génica predicha genéticamente o imputada. Esta metodología resulta de suma importancia ([Gusev et al., 2016](#)). El TWAS opera conceptualmente y de manera efectiva en dos fases. En la primera fase, se llevan a cabo el entrenamiento de modelos de aprendizaje automático. Frecuentemente se emplean modelos de regresión lineal penalizada clásicos como Lasso ([Tibshirani, 1996](#)) o Elastic Net ([Zou y Hastie, 2005](#)), metodologías que han demostrado un rendimiento óptimo y que después de tanto tiempo siguen siendo el estándar actual en los estudios TWAS ([Okoro et al., 2021](#); [Evans et al., 2024](#)). Todo ello se realiza mediante el uso de paneles de referencia de tejidos transcriptómicos, como los que provienen del proyecto Genotype-Tissue Expression (GTEx) o del CommonMind Consortium (CMC).

El objetivo en el ámbito matemático consiste en estimar un vector de pesos (W) que modela el nivel de expresión estable de un gen (E) como una combinación lineal de los genotipos de los SNPs locales (representados en una matriz X), más un término de error ϵ que recoge la variabilidad no explicada (incluidos factores ambientales, ϵ):

$$E = X \cdot W + \epsilon$$

En la segunda fase, estos pesos precomputados de manera específica se cruzan con las estadísticas de resumen (tamaños de efecto, como el *Z-score* o la *Odds Ratio*) obtenidas del GWAS de la cohorte de estudio. Herramientas algorítmicas como FUSION permiten inferir la asociación gen-rasgo al evitar la medición directa del ARN en los individuos de la cohorte del GWAS. Esta aproximación no solo reduce la carga de comparaciones múltiples, al pasar de millones de SNPs a unas decenas de miles

de genes transcritos. Además, aumenta significativamente el poder estadístico y proporciona una diana funcional directa: el gen ([Wainberg et al., 2019](#)).

4.3. DESENTRAÑANDO LA SEÑAL: DESEQUILIBRIO DE LIGAMIENTO Y REDES FUNCIONALES

La identificación de un gen asociado transcriptómicamente a un fenotipo a través de TWAS no implica automáticamente que dicho gen juegue un papel causal sobre el fenotipo. El factor más destacado de confusión algorítmica que se presenta en estas metodologías es el desequilibrio de ligamiento (LD, por sus siglas en inglés). El LD describe la correlación no aleatoria entre alelos en diferentes *loci*. Esto provoca que un gen sin efecto causal real pueda mostrar una fuerte señal de asociación y esto sucede simplemente por encontrarse coheredado genómicamente cerca de una variante o gen que está verdaderamente asociado al fenotipo ([Mancuso et al., 2019](#)).

Para discriminar señales independientes o *drivers* de aquellas originadas por contaminación, se implementan métodos de análisis condicional. Además, se utilizan métodos de conjunto (*hitchhiking*) y conjunto (*joint/conditional analysis*). Estos métodos recalculan tanto el tamaño del efecto como el *p*-valor de un gen, mientras que matemáticamente se condiciona el modelo a la expresión de los genes circundantes o a los SNPs de ese mismo *locus*, empleando matrices de correlación de LD. Si la señal de un gen decae drásticamente al condicionarlo por un gen adyacente, se puede deducir que su asociación era un artefacto del LD. Esto refina la lista de candidatos viables.

Finalmente, los genes que han sido validados y priorizados no actúan de manera aislada. Ellos interactúan a través de complejas interacciones bioquímicas. El análisis de enriquecimiento funcional permite, de manera adecuada, trasladar la lista de genes topológicamente aislados a un contexto fisiológico. Matemáticamente, este análisis determina si la proporción de genes vinculados a un

fenotipo en una vía biológica específica (como las definidas en las ontologías Gene Ontology o KEGG Pathways) es significativamente superior a la esperada por azar. Este notable contraste de sobrerrepresentación se calcula clásicamente mediante pruebas exactas de Fisher o aproximaciones basadas en la distribución hipergeométrica, controlando rigurosamente la tasa de falsos descubrimientos mediante correcciones estadísticas como el método de Benjamini-Hochberg ([Reimand et al., 2019](#)).

5. METODOLOGÍA

5.1. ORIGEN DE LOS DATOS

El punto de partida del análisis fueron las *summary statistics* (estadísticas de resumen) obtenidas a partir de un estudio de asociación de genoma completo (GWAS) previo. Este estudio evaluó la arquitectura genética de tres fenotipos psiquiátricos distintos: el trastorno depresivo mayor (MDD), el trastorno bipolar (BD) y la tentativa de suicidio (SA). Dichos datos provienen del grupo de investigación liderado por el Dr. Claudio Toma en el Centro de Biología Molecular Severo Ochoa (CBMSO-CSIC). Este equipo, centrado en la psiquiatría traslacional y la genética humana, investiga la base biológica de trastornos psiquiátricos complejos mediante el análisis de variantes genéticas comunes, raras y estructurales. Para la generación de este tipo de datos, el grupo emplea tecnologías de secuenciación de alto rendimiento (*high-throughput*) y metodologías bioinformáticas a gran escala. Además, enmarcan su investigación en grandes redes colaborativas, como el Consorcio de Psiquiatría Genómica, a través del cual han contribuido recientemente a la identificación de nuevas dianas genéticas en el trastorno bipolar a nivel global ([O'Connell et al., 2025](#) y [Toma et al., 2026](#)).

El acceso a esta base de datos se ha llevado a cabo de manera restringida e interna, contando con el consentimiento explícito, así como con la autorización directa de los investigadores principales del proyecto para su explotación y análisis exclusivo en el marco de este Trabajo de Fin de Grado.

Como se ha mencionado anteriormente, el presente trabajo no manejó datos genéticos de nivel individual, sino exclusivamente estadísticas de resumen agregadas y anonimizadas (*summary statistics*), de las que no es posible reidentificar a ningún participante. El uso del GWAS de origen contó con la aprobación de los comités éticos correspondientes y el consentimiento informado de los participantes. El acceso a estos datos se realizó de forma restringida e interna, con autorización expresa de los investigadores principales para su uso exclusivo en este Trabajo de Fin de Grado, sin que los datos originales se incorporen ni se redistribuyan en el material entregado ([Toma et al., 2026](#)).

Con el objetivo de abordar la base genética de cada una de las condiciones, se llevaron a cabo procesos sobre tres archivos independientes que contenían los resultados estadísticos brutos de las asociaciones entre cientos de miles de polimorfismos de nucleótido único y su respectivo fenotipo. Las cohortes que se analizaron se distribuyeron de la siguiente manera:

- **Trastorno depresivo mayor:** Archivo *danerMadManicMDDallv1_050226*, formado por una cohorte de 325 casos y 4156 controles, con un total de 4481 individuos.
- **Trastorno bipolar:** Archivo *danerMadManicBD_020226.sumstats*. Este comprende una cohorte de 527 casos y 4160 controles, esto es, 4687 individuos.
- **Tentativa de suicidio:** Archivo *danerSAall_090226.sumstats*, que está compuesto por una cohorte de 812 casos y 4446 controles y un total de 5258 individuos.

Cabe destacar que, aunque en las secciones posteriores de esta metodología se ilustren los procedimientos técnicos y computacionales utilizando un fenotipo en particular a modo de ejemplo representativo, el flujo de trabajo bioinformático detallado se aplicó de forma sistemática, independiente e idéntica a los tres conjuntos de datos. Los datos de genotipado provienen de una cohorte reclutada en Madrid y de ascendencia mayoritariamente española. Dado que la población ibérica (IBS, Iberian Population in Spain) se integra en la superpoblación europea (EUR) del proyecto 1000 Genomas, el uso del panel de referencia de LD 1000G EUR y del panel eQTL del consorcio CMC (mayoritariamente europeo) satisface razonablemente el requisito de concordancia ancestral (*ancestral matching*) necesario en un análisis TWAS, asumiendo que la estructura de LD ibérica es una buena aproximación de la europea de referencia.

5.1.1. ESTRUCTURA COMPUTACIONAL RELACIONADA CON LOS DATOS DE ORIGEN

Todos los archivos originales comparten una misma arquitectura tabular. Esta arquitectura está compuesta por 12 variables principales. Con el objetivo de entender la naturaleza de las métricas implementadas en el algoritmo de imputación, se expone a continuación el sentido estadístico y biológico de cada columna:

- **CHR:** Cromosoma físico al que pertenece el SNP.
- **SNP:** Identificador único de la variante genética (habitualmente su número de identificación *rs*).
- **BP:** Posición física exacta de la variante en el genoma (*Base Pair*).
- **A1:** Alelo evaluado (alelo de efecto). El sentido de su efecto a nivel del SNP viene dado por el *Odds Ratio*: un $OR > 1$ indica que A1 es un alelo de riesgo y un $OR < 1$ que es protector. De forma equivalente, el *Z-score* que se calcula posteriormente ($Z = \frac{\ln(OR)}{SE}$) hereda ese signo (positivo para alelos de riesgo y negativo para alelos protectores). La direccionalidad del efecto a nivel de gen se interpreta más adelante mediante el estadístico TWAS.Z.
- **A2:** Alelo alternativo al alelo evaluado.
- **FRQ_A_812:** Frecuencia alélica observada en el grupo de casos (en esta cohorte, por ejemplo, 812 personas que presentaron tentativa de suicidio).
- **FRQ_U_4446:** Frecuencia alélica observada en el grupo de controles (En este caso, 4.446 personas no presentaron el fenotipo).
- **INFO:** Métrica de calidad que evalúa la fiabilidad de la imputación estadística del marcador genético.
- **OR:** Tamaño del efecto de la asociación expresado como *Odds Ratio*.

- **SE:** Error estándar (*Standard Error*) de la medición estadística.
- **P:** *P*-valor (*p-value*) de la asociación.
- **ngt:** Número de estudios en los que el SNP fue genotipado directamente (no imputado).

5.2. CONTROL DE CALIDAD (QC) Y PREPROCESAMIENTO COMPUTACIONAL

El software FUSION exige un formato de entrada muy específico y restrictivo, tal y como se encuentra documentado oficialmente en el manual de usuario y en la metodología publicada por sus desarrolladores originales ([Gusev et al., 2016](#); <http://gusevlab.org/projects/fusion/>). Necesita un archivo de texto plano separado por tabulaciones con exactamente cuatro columnas (*SNP*, *A1*, *A2*, *Z*). Las tres primeras corresponden con las columnas que se han explicado anteriormente y la última, *Z*, es el resultado de la división entre el logaritmo natural de la *Odds Ratio* y el error estándar, que además se explicará más adelante en el presente trabajo ([Gusev et al., 2016](#)). Por tanto, fue necesario un preprocesamiento que adecuara los datos al formato y a los requisitos del programa. Este consistió, de forma específica, en la eliminación de las filas con valores ausentes en OR, SE o *p*, en la exclusión de los *Odds Ratios* no válidos ($OR \leq 0$) y en el cálculo del estadístico *Z* a partir de OR y SE (Shi, 2017).

Para este propósito en concreto, se desarrolló un script en R llamado *limpiar_daner.R*, que sirvió para ejecutar los pasos de forma secuencial que se mencionan a continuación (véase el 9.1).

5.2.1. LIMPIEZA DE DATOS FALTANTES (NAS)

El análisis inicial del archivo crudo reveló la presencia de filas donde los valores estadísticos clave (OR, SE o P) figuraban como «NA» (*Not Available*). Esto ocurre cuando el algoritmo del GWAS original no pudo converger para un SNP específico en ese caso. Además, se exigió que el OR fuera estrictamente mayor que cero.

Filtro en R:

```
datos_limpios <- subset(datos, !is.na(OR) & !is.na(SE) & OR > 0)
```

5.2.2. CÁLCULO DEL ESTADÍSTICO Z (Z-SCORE)

Para calcular el puntaje Z, la metodología matemática exige aplicar logaritmos neperianos sobre la *Odds Ratio* original. Intentar calcular el logaritmo para un NA o para un valor negativo provocaría un error de valor no numérico o indefinido que detendría la ejecución del *pipeline*, con lo que es indispensable la depuración previa y exhaustiva de estas filas.

FUSION no usa directamente el OR para el uso de sus modelos predictivos, sino que requiere estadísticos estandarizados (*Z-scores*). De acuerdo con las recomendaciones metodológicas para el manejo de *summary statistics*, el *Z-score* fue derivado matemáticamente a partir del OR y el SE por medio de la siguiente fórmula:

$$Z = \frac{\ln(OR)}{SE}$$

El OR presenta una distribución asimétrica (va desde 0 hasta 1 para factores de protección y desde 1 hasta infinito para factores de riesgo). El logaritmo neperiano (*ln*) aplicado transforma esta

distribución a una escala lineal y simétrica centrada en cero. En el contexto de un GWAS para rasgos binarios, este valor logarítmico equivale exactamente al coeficiente *beta* (β) obtenido de la regresión logística subyacente. Si este valor se divide entre el error estándar (*SE*), se pondera el tamaño del efecto según la certidumbre estadística de la medición, logrando un *Z-score* que indica a cuántas desviaciones estándar del «no-efecto» se encuentra la variante genética.

5.2.3. GENERACIÓN DEL ARCHIVO DE ENTRADA

Después de aplicar estos filtros de calidad, así como las transformaciones matemáticas pertinentes, se procedió a aislar exclusivamente las 4 columnas requeridas por el analizador de FUSION (SNP, A1, A2, Z). La eliminación del resto de metadatos genómicos presentes en el archivo original resulta indispensable no solo para cumplir adecuadamente con las exigencias del analizador, sino también para optimizar de forma drástica el consumo de memoria RAM en el transcurso del cruce de datos con los paneles de expresión. El resultado final se exportó bajo el nombre *sumstats_suicidio_FUSION_FINAL.txt*. Este archivo constituye la matriz de entrada definitiva.

El orden secuencial de este preprocesamiento obedece a una restricción metodológica estricta. No era posible aislar las cuatro columnas definitivas como paso inicial ya que la variable Z no existía en los datos crudos: hubo que calcularla a partir de las métricas OR y SE. Por lo tanto, el primer paso consistió en eliminar las filas con valores nulos para no provocar un error a la hora de calcular los logaritmos que se utilizan para determinar el estadístico Z. Una vez que las variables originales cumplieran su función operativa, se ejecutó el recorte dimensional de la tabla para obtener la submatriz final requerida por FUSION. Cabe precisar que el control de calidad se limitó a estos pasos y no incluyó un filtrado adicional por calidad de imputación (INFO) o por frecuencia alélica mínima (MAF), ni la eliminación de variantes con alelos ambiguos (A/T, C/G) o duplicadas. Este último ya

se incluía en el propio programa de FUSION: la concordancia y orientación de alelos frente al panel de referencia se delegó en el emparejamiento interno que realiza FUSION durante el cruce de datos.

5.3. PREPARACIÓN DEL ENTORNO INFORMÁTICO Y RECURSOS GENÓMICOS

La ejecución de un estudio de asociación de transcriptoma completo (TWAS) exige una infraestructura computacional altamente especializada, adecuada para integrar estadísticos de resumen genómicos con referencias poblacionales y modelos de expresión tisular empíricos. Este apartado proporciona una descripción detallada sobre la configuración integral del marco analítico. Este es el componente necesario para llevar a cabo el estudio. En primer lugar, se describe la habilitación del entorno estadístico en R, así como la compilación de sus dependencias críticas para el procesamiento de datos a gran escala. A continuación, se expone la incorporación de los recursos biológicos externos fundamentales dentro del ecosistema FUSION, destacando los paneles poblacionales de desequilibrio de ligamiento (LD) así como los pesos de transcripción específicos para la corteza prefrontal dorsolateral (DLPFC). Por último, se desglosan los fundamentos matemáticos subyacentes para justificar el rigor de la herramienta. Esto demuestra cómo la convergencia de estos recursos informáticos mediante modelos de álgebra lineal permite inferir el riesgo transcriptómico con un alto poder estadístico. El análisis se ejecutó con FUSION (versión del repositorio público de Gusev *et al.*, descargada en marzo de 2026, bajo R 4.3.1 sobre WSL (Ubuntu). El conjunto de scripts y resultados que sustentan este trabajo se organiza en un paquete reproducible (.zip) estructurado en carpetas por fase del *pipeline* (datos procesados, código, resultados del TWAS, resultados del análisis condicional, genes priorizados y figuras), acompañado de un archivo README.txt que documenta el flujo de ejecución y las dependencias externas.

5.3.1. INSTALACIÓN EN R Y DEPENDENCIAS CRÍTICAS

Dentro del entorno Ubuntu, se procedió con la instalación del núcleo estadístico R (`r-base-core`) a través del gestor de paquetes APT.

La ejecución de FUSION requiere de paquetes específicos de R que actúan como «diccionarios» para interpretar formatos genómicos complejos. A lo largo de esta fase se presentaron incidencias técnicas.

1. Paquete **optparse**: Instalado con éxito desde el CRAN oficial para la gestión de argumentos por línea de comandos.

2. Paquete **plink2R**: Este paquete, fundamental para que R pueda hacer la lectura de los archivos binarios PLINK del panel de referencia (`.bed`, `.bim`, `.fam`), no está incluido en repositorios que son estándar. Su instalación manual desde el repositorio de GitHub requirió de la descarga del código fuente en formato `.zip` y su compilación local.

3. Resolución de dependencias **C++**: La compilación de `plink2R` falló inicialmente por la ausencia de librerías de álgebra lineal avanzadas. Este contratiempo se resolvió instalando previamente los paquetes `Rcpp` y `RcppEigen` en R. Debido a esto, la integración de `plink2R` en el entorno fue exitosa.

5.3.2. DESCARGA Y CONFIGURACIÓN SOBRE EL ECOSISTEMA FUSION

Una vez que el entorno informático fue preparado y una vez que el archivo GWAS fue formateado, se procedió a la descarga del software principal. Además, se procedió a la descarga de los paneles de referencia genómica y transcriptómica que fueron necesarios para el cruce de datos. Es preciso tener un mapa genético poblacional para el análisis TWAS. Se descargó el panel de referencia europeo del proyecto 1000 Genomes (1000G.EUR).

El desequilibrio de ligamiento (LD) describe la herencia conjunta de variantes genéticas cercanas en el cromosoma, formando «bloques» o haplotipos. Si un gen está regulado mediante múltiples SNPs en alto LD, sumar sus efectos estadísticos brutos inflaría artificialmente el resultado (falsos positivos por redundancia). El panel LDREF permite que FUSION modele esta correlación y ajuste el estadístico final, asegurando así que cada señal genética se cuente correctamente.

5.3.3. MODELOS SOBRE EXPRESIÓN TRANSCRIPTÓMICA (LOS PESOS DEL MODELO)

El núcleo del análisis radicaba en torno a proyectar las variantes genéticas sobre un tejido biológicamente relevante para el fenotipo objetivo. Se seleccionaron los modelos predictivos de expresión génica de la corteza prefrontal dorsolateral (DLPFC), que fueron generados mediante secuenciación de ARN (RNA-seq) por el CommonMind Consortium (CMC). Las especificaciones técnicas de este panel de referencia, que abarca 452 muestras además de más de 5000 características transcripcionales, se encuentran detalladas en el repositorio oficial del ecosistema FUSION.

La Figura 1 corresponde al repositorio oficial de FUSION y presenta los pesos de expresión génica precomputados. Para el presente análisis, se descargó el modelo correspondiente a la cuarta fila. Este modelo es de tejido de la corteza prefrontal dorsolateral (DLPFC) secuenciado por el CommonMind Consortium (CMC).

Single tissue gene expression

Tissue	Assay	# Samples	# Features	Study
 Peripheral Blood	RNA array	1,247	2,454	[1] NTR
 Whole blood	RNA array	1,264	4,701	[2] YFS
 Adipose	RNA-seq	563	4,671	[3] METSIM
 Brain (DLPFC)	RNA-seq	452	5,420	[4] CMC
 Brain (DLPFC)	RNA-seq splicing	452	7,772	[4] CMC

Figura 1. Modelos de expresión génica de tejido único disponibles en el repositorio de FUSION.

Adaptado de la fuente FUSION / TWAS, por A. Gusev, s.f.

5.3.4. FUNDAMENTOS MATEMÁTICOS DEL MODELO TWAS: DESEQUILIBRIO DE LIGAMIENTO (LD) Y VARIANZA COMBINADA

El software FUSION ([Gusev et al., 2016](#)) estima de manera efectiva la asociación entre la expresión génica predicha en un tejido diana (en este estudio, la corteza prefrontal dorsolateral) y un fenotipo clínico utilizando únicamente estadísticas de resumen de GWAS (*summary statistics*), sin necesidad de acceder a genotipos individuales. Este proceso se fundamenta en los siguientes pilares bioinformáticos y matemáticos.

5.3.4.1. EL DESEQUILIBRIO DE LIGAMIENTO (LD) COMO MATRIZ DE CORRELACIÓN

El desequilibrio de ligamiento (LD) se refiere a la asociación que no es aleatoria de alelos situados en distintos *loci* dentro de un cromosoma. En el ámbito matemático, el LD funciona como una matriz de covarianza o correlación (Σ) entre los SNPs.

FUSION utiliza una matriz de referencia de LD (proveniente de una población genéticamente emparejada, como el reconocido proyecto 1000 Genomas) para modelar la estructura de correlación lineal entre los SNPs de la región del gen. Tener en cuenta esto es clave, pues los SNPs no son independientes entre sí, sino que están correlacionados en bloques.

5.3.4.2. MODELADO MEDIANTE ÁLGEBRA LINEAL Y PESOS DE EXPRESIÓN

Los datos de referencia del consorcio CommonMind son utilizados para el entrenamiento de modelos de regresión penalizada. Estos modelos, como Lasso o Elastic Net, permiten obtener un vector de pesos genéticos W . Cada elemento w_i representa el efecto predictivo del SNP i sobre la expresión del gen en la corteza prefrontal. Suponiendo que tuviéramos acceso a los genotipos individuales en una matriz X , la expresión génica predicha $\hat{G}$ para un individuo se calcularía mediante un producto de matrices (álgebra lineal):

$$\hat{G} = XW$$

Dado que solo contamos con las estadísticas de resumen del GWAS (los efectos marginales de los SNPs, expresados como puntuaciones Z), FUSION utiliza una transformación lineal para estimar la puntuación Z del gen (Z_{TWAS}) empleando la matriz de LD (Σ) y el vector de pesos (W):

$$Z_{TWAS} = \frac{W'Z_{GWAS}}{\sqrt{W'\Sigma W}}$$

Donde W' representa el vector transpuesto de pesos. Además, $W'\Sigma W$ denota la varianza del predictor genético ajustada por la correlación (LD) entre los SNPs.

5.3.4.3. CORRECCIÓN POR REDUNDANCIA Y VARIANZA COMBINADA

Cuando se evalúa el efecto combinado de diversas variantes que están correlacionadas (en LD), no se pueden sumar sus efectos de manera simple, puesto que se sobreestimaría la señal (redundancia). Aquí es donde entra la fórmula de la varianza para variables correlacionadas. Para entender correctamente cómo se deduce estadísticamente la aproximación de FUSION, consideremos el caso simplificado de combinar dos señales o variables correlacionadas (A y B). Cada una tiene un peso de expresión (W_A, W_B) y una estadística de asociación GWAS (Z_A, Z_B). La combinación lineal de estas dos variables se establece como:

$$Z_{combinada} = \frac{W_A Z_A + W_B Z_B}{\sqrt{\text{Var}(W_A Z_A + W_B Z_B)}}$$

Aplicando las propiedades de la varianza para dos variables aleatorias dependientes, la segunda variable es donde $\text{Var}(Z) = 1$ para puntuaciones estándar Z . Además, ρ representa el

coeficiente de correlación de LD entre el SNP A y el SNP B. Así, la varianza combinada en el denominador se expande matemáticamente como:

$$\text{Var}(W_A Z_A + W_B Z_B) = W_A^2 \text{Var}(Z_A) + W_B^2 \text{Var}(Z_B) + 2W_A W_B \text{Cov}(Z_A, Z_B)$$

Como las puntuaciones Z están estandarizadas, se tiene que $\text{Var}(Z) = 1$ y la covarianza se convierte directamente en la correlación de LD (ρ). Por tanto, la fórmula final que utiliza el álgebra de FUSION para efectivamente resolver la redundancia biológica y obtener la Z final es:

$$Z_{\text{combinada}} = \frac{W_A Z_A + W_B Z_B}{\sqrt{W_A^2 + W_B^2 + 2W_A W_B \rho}}$$

Este modelo matemático facilita que FUSION limpie la redundancia. Esto es provocado por el desequilibrio de ligamiento. Si dos SNPs se encuentran en perfecto LD ($\rho = 1$), el denominador incrementa para penalizar aquella redundancia y evitar falsos positivos. Si son independientes ($\rho = 0$), el término de covarianza desaparece. Por consiguiente, se comporta como una suma de varianzas clásica. Este ajuste computacional preciso es el que dota al estudio de un alto poder estadístico sin comprometer el rigor analítico ([Wainberg et al., 2019](#)).

5.4. REALIZACIÓN DEL ANÁLISIS DE ASOCIACIÓN TRANSCRIPTÓMICA (TWAS)

Con todos los elementos dispuestos en el mismo directorio de trabajo (el script ejecutable de FUSION, los estadísticos de resumen del GWAS limpios, el panel de referencia LD y los pesos de expresión génica del tejido cerebral), se inició la fase de computación algorítmica. Este proceso se

ejecutó en una terminal Bash mediante el Subsistema de Windows para Linux (WSL), empleando la versión 4.3.1 de R. El análisis se estructuró metodológicamente en tres etapas consecutivas: en primer lugar, una validación técnica del *pipeline* sobre un único cromosoma para verificar la integridad de los datos; en segundo lugar, la automatización y escalado del análisis al genoma completo; y, finalmente, la monitorización del registro de exclusión génica junto con el aislamiento por control de calidad de regiones de alta complejidad, como el complejo mayor de histocompatibilidad (MHC).

5.4.1. VALIDACIÓN DEL PIPELINE CON EL CROMOSOMA 22

Como medida de control de calidad analítico, la primera ejecución se limitó solo al cromosoma 22, ya que es el de menor longitud. El comando ejecutado (`Rscript FUSION.assoc_test.R ... --chr 22`) arrojó un éxito rotundo, pues el algoritmo analizó los 157 genes de la corteza prefrontal codificados en este cromosoma sin registrar pérdidas de información (`0 / 157 genes were skipped`). Esto confirmó que el formateo previo de los *Z-scores* y la estructura de directorios eran correctos.

5.4.2. ANÁLISIS CON EL GENOMA COMPLETO (CROMOSOMAS 1-22)

Una vez validado el proceso, se implementó así un bucle de automatización (*shell scripting*) para poder ejecutar el algoritmo de forma secuencial sobre los 22 cromosomas autosómicos:

Bash

```
for chr in {1..22}; do
  Rscript FUSION.assoc_test.R \
  --sumstats sumstats_suicidio_FUSION_FINAL.txt \
  --weights WEIGHTS/CMC.BRAIN.RNASEQ.pos \
  --weights_dir WEIGHTS/ \
  --ref_ld_chr LDREF/1000G.EUR. \
  --chr $chr \
  --out SUICIDIO_TWAS_chr${chr}.txt
done
```

5.4.3. EXCLUSIÓN DE GENES Y MANEJO DE LA REGIÓN MHC

Durante el procesamiento sobre los 5379 genes totales, el registro de consola documentó la exclusión automática de una proporción ínfima (4 genes, < 0.1 %). FUSION descarta genes según dos premisas estrictas y conservadoras:

- Superposición predictiva ausente: Tal como sucedió con el gen *TBX15* (cromosoma 1), aun cuando el GWAS contenía SNPs dentro de dicha región, ninguno correspondía a las variantes con peso funcional distinto a cero en el modelo transcriptómico.
- Imputación de baja confianza: FUSION imputa estadísticamente los SNPs faltantes usando el panel LD. La confianza matemática de esta imputación se evalúa por medio del coeficiente de determinación r^2 , que representa la correlación al cuadrado entre el genotipo verdadero (G) y el genotipo estadísticamente imputado ($E(G)$), calculándose formalmente de la siguiente manera:

$$r^2 = \frac{(\text{Cov}(G, E(G)))^2}{\text{Var}(G) \cdot \text{Var}(E(G))}$$

En caso de que la confianza matemática de esta imputación (r^2) sea inferior al umbral de seguridad (0.70), como ocurrió con el gen *NOTCH2NL* ($r^2 = 0.64$), se omite el gen para prevenir falsos descubrimientos.

Adicionalmente, los resultados correspondientes al cromosoma 6 mostraron una advertencia específica respecto al complejo mayor de histocompatibilidad (MHC). A causa de la extrema

densidad génica y los complejos patrones de recombinación evolutiva de esta región vinculada al sistema inmunitario, FUSION segrega automáticamente estos resultados en un archivo aislado (.MHC). Esto impide que artefactos estadísticos que se derivan de su intrincada estructura de desequilibrio de ligamiento puedan contaminar al análisis principal.

5.5. INTERPRETACIÓN ANALÍTICA DE LA SALIDA DE DATOS

Un fichero de salida estándar fue generado para cada cromosoma por el pipeline. A continuación, se presenta de forma detallada la significación tanto biológica como estadística de cada columna resultante:

- **PANEL:** Es el identificador del panel de pesos (si aplica).
- **FILE:** Ruta local completa hacia el archivo del modelo de pesos del gen (.wgt.RDat).
- **ID:** Identificador oficial del gen (ej. *PRODH*, *IL17RA*).
- **CHR:** Cromosoma en donde se localiza al gen.
- **P0 / P1:** Posición física en pares de bases (su inicio y fin) del gen dentro del cromosoma.
- **HSQ** es la heredabilidad estimada del nivel de expresión del gen.
- **BEST.GWAS.ID / BEST.GWAS.Z:** Identificador (rsID) y *Z-score* absoluto del SNP individual con mayor significación estadística dentro de las coordenadas del gen en nuestro archivo GWAS original. Es el SNP con mayor significación en esa región en el GWAS original del fenotipo.
- **EQTL.ID:** Es el SNP regulador (eQTL) que, según los datos de GTEx/CMC, presenta el mayor efecto sobre la expresión del gen.

- **EQTL.Z:** Es el efecto del eQTL sobre la expresión del gen. Un valor negativo indica que el alelo considerado se asocia a una menor expresión del gen.
- **EQTL.GWAS.Z:** Es el efecto de ese mismo eQTL sobre el fenotipo. Un valor negativo indica que el alelo considerado se asocia a un menor riesgo de la enfermedad.
- **NSNP:** Es el número total de SNPs superpuestos que son analizados para componer el modelo de ese gen.
- **MODEL:** El algoritmo matemático penalizado (Ej. *lasso*, *enet*, *bslmm*) que ajustó mejor la predicción de expresión para ese *locus*.
- **MODEL.CV.R2 / MODEL.CV.PV:** Es el coeficiente de determinación (r^2) y el p -valor de la validación cruzada del modelo. Indican la robustez general de la predicción transcriptómica.
- **TWAS.Z:** Es el estadístico principal de interés, el Z -score que se obtiene al proyectar nuestros datos genéticos del fenotipo sobre el modelo de expresión. Su signo indica cuál es la dirección del efecto biológico: un valor positivo asocia una más alta expresión del gen en el cerebro con un más alto riesgo de tentativa de suicidio, mientras que un valor negativo indica un efecto de tipo protector.
- **TWAS.P:** El p -valor asociado al estadístico TWAS.Z, que determina la significación estadística final de la asociación entre la expresión del gen y el fenotipo estudiado.

Sin embargo, conviene ahondar en lo que implica el estadístico TWAS.Z con mayor profundidad. A priori, puede entenderse como el estadístico que resume la asociación global entre la expresión predicha del gen y el fenotipo. Es el estadístico final que cuantifica la relación directa entre la cantidad de ARN que produciría ese gen en el cerebro como componente heredable y el riesgo de que ese paciente intente suicidarse. Resume en un solo número la dirección del efecto y nuestra

certeza estadística. Si es positivo, actúa como factor de riesgo (esto es, si aumenta la expresión del gen, aumenta el riesgo de suicidio); mientras que, si es negativo, actúa como factor protector (es decir, si aumenta la expresión del gen, disminuye el riesgo de suicidio).

Bajo la hipótesis nula se asume que no existe asociación entre la expresión predicha de un gen y el fenotipo, de modo que el efecto real sería 0. El estadístico TWAS.Z es una combinación lineal de los Z-scores de los SNPs del GWAS, los cuales, por construcción (estadístico de Wald), siguen aproximadamente una distribución normal estándar bajo H_0 . Como una combinación lineal de variables aproximadamente normales es a su vez aproximadamente normal, el TWAS.Z se distribuye de forma aproximadamente normal estándar bajo la hipótesis nula (media 0 y desviación típica 1), siempre que se cumplan las condiciones del modelo. Por tanto, el TWAS.Z indica cuántas desviaciones típicas se aleja el resultado observado del valor esperado bajo H_0 .

El p -valor bilateral se obtiene como $p = 2(1 - \Phi(|Z|))$, donde Φ representa la función de distribución acumulada de la normal estándar. Por ejemplo, si $Z = 1.96$, entonces $\Phi(1.96) \approx 0.975$. El área de la cola derecha sería $(1 - 0.975 = 0.025)$ y al tratarse de un contraste bilateral se multiplica por 2, obteniéndose aproximadamente 0.05. El motivo de multiplicar por 2 se basa en considerar los dos extremos de la distribución: asociaciones muy positivas y asociaciones muy negativas. Es decir, resultan interesantes tanto valores de Z muy superiores a 0 como valores muy inferiores a 0.

Por último, conviene explicar qué representa exactamente el p -valor, ya que deriva del valor de Z . Es la probabilidad de obtener un resultado tan extremo o más extremo que el observado suponiendo que la hipótesis nula fuera cierta. En otras palabras, es $p = P(|Z| \geq |z_{obs}| \mid H_0)$.

A modo de orientación, si el valor Z resultara ser 0, indicaría ausencia de asociación entre la expresión del gen y el fenotipo. Si diera como resultado 1.96, por ejemplo, ya correspondería con el

clásico umbral de p -valor = 0.05. Si, por otro lado, el valor Z fuese 4 o -4 , se consideraría como una asociación más fuerte.

5.6. ANÁLISIS ESTADÍSTICO Y VISUALIZACIÓN A ESCALA GENÓMICA

Después de completarse el proceso iterativo del *pipeline* FUSION en los 22 autosomas, se produjeron 22 ficheros de salida separados (*SUICIDIO_TWAS_chr1.txt* hasta *chr22.txt*). Fue imperativo consolidar todos estos datos en un único archivo maestro para proceder con el análisis estadístico global y la visualización.

Se usó una combinación de comandos de procesamiento de texto en el entorno Linux (*cat* y *awk*) para concatenar los archivos, asegurando que la cabecera (nombres de las columnas) se conservara solamente en la primera línea del archivo resultante y se omitiera en las fusiones subsecuentes.

Bash

```
cat SUICIDIO_TWAS_chr*.txt | awk 'NR==1 || !/^PANEL/' >  
RESULTADOS_TWAS_COMPLETOS.txt
```

Este proceso generó por completo el archivo maestro *RESULTADOS_TWAS_COMPLETOS.txt*, que contuvo todos los estadísticos de asociación de transcripción para los genes analizados de la corteza prefrontal dorsolateral (más de 5300 modelos génicos válidos).

5.6.1. CORRECCIÓN POR PRUEBAS MÚLTIPLES (UMBRAL DE BONFERRONI)

En los estudios genómicos, donde se llevan a cabo miles de pruebas estadísticas de manera simultánea (en este caso, contrastando más de 5000 genes independientemente), la probabilidad de obtener falsos positivos por azar puro aumenta de manera drástica. Para controlar el ratio de falsos positivos (Tasa de error por familia – FWER), se aplicó la corrección de Bonferroni.

El umbral de significación genómica estricto se calculó dividiendo el nivel de significación estándar ($\alpha = 0.05$) entre el número total de genes analizados con éxito en el modelo:

$$\alpha_{\text{Bonferroni}} = \frac{0.05}{N_{\text{genes}}}$$

Únicamente los genes con un p -valor de asociación (TWAS.P) por debajo de este umbral estricto (p menor a 10^{-5}) se considerarían descubrimientos estadísticamente robustos a nivel de transcriptoma completo.

Sin embargo, para este tipo de estudios, como un $N = 5258$ se dispone de muy poca potencia estadística para aplicar la corrección de Bonferroni y obtener algún resultado. Esto se debe a que si, por ejemplo, se cuenta con 5000 genes, el p -valor ajustado sería $\frac{0.05}{5000} = 0.00001$. No obstante, en virtud de tener tan relativa escasa potencia estadística y una N que ronda entre 4000 y 5000, en el presente trabajo se aplica de manera exploratoria y arbitraria un TWAS.P < 0.001, con el objetivo de prevenir falsos negativos (error tipo II). Sin embargo, es importante reconocer la limitación de que el precio a pagar es el aumento de error tipo I. ([Gusev et al., 2016](#); [Wainberg et al., 2019](#)).

5.6.2. ANÁLISIS ESTADÍSTICO CON VISUALIZACIÓN MEDIANTE MANHATTAN PLOT

La fase final del análisis de datos fue trasladada al entorno de desarrollo RStudio para manipulación estadística y representación gráfica de los resultados a escala genómica.

El archivo maestro se importó a R y se efectuó un filtrado de limpieza para quitar registros sin un p -valor de asociación válido ($TWAS.P = NA$). A continuación, se estructuró bajo especificaciones un *Data Frame* adaptado a los requisitos del paquete de visualización *qqman*, seleccionando las variables clave: Cromosoma (CHR), posición inicial del gen (BP), p -valor del TWAS (P) y el identificador del gen (SNP/ID). Para la representación visual de las asociaciones que existen a lo largo del genoma, se generó un gráfico conocido como gráfico de Manhattan (*Manhattan Plot*).

A modo ilustrativo, en la Figura 2. Ejemplo representativo de un Manhattan plot en un estudio TWAS. se muestra un ejemplo de la morfología y disposición de este tipo de gráficos en el contexto de un estudio de asociación transcriptómica. Cada punto indexado en el gráfico corresponde a un gen evaluado. El eje horizontal (X) organiza los genes según su posición física cromosómica a lo largo de los 22 autosomas. El eje vertical (Y) representa el nivel de significación estadística transformado logarítmicamente ($-\log_{10}(P)$); a mayor altura en el eje, menor es el p -valor y, por tanto, más significativa es la asociación entre la expresión génica imputada y el fenotipo. Los genes que superan el umbral establecido se destacan mediante su anotación oficial.




Figura 2. Ejemplo representativo de un Manhattan plot en un estudio TWAS.

Adaptado de "Transcriptome-wide association study identifies new susceptibility genes and pathways for spondyloarthritis", por [X. Su, A. Chen, M. Teng, W. Ji y Y. Zhang, 2023](#), BMC Musculoskeletal Disorders, 24(1), p. 430 (<https://doi.org/10.1186/s12891-023-06541-1>). CC BY 4.0.

En este tipo de representaciones, la interpretación formal se rige bajo los siguientes parámetros:

- **Eje X:** muestra la posición física de cada gen a largo de los 22 autosomas.
- **Eje Y:** Representa el nivel de significación estadística transformado de forma logarítmica ($-\log_{10}(p)$). Cuanto mayor es el valor alcanzado en este eje, más robusta es la asociación estadística entre la expresión heredable de dicho gen y el rasgo analizado.
- **Líneas de umbral:** Se establece una línea horizontal para delimitar el umbral de significación tras la corrección por pruebas múltiples (Bonferroni), complementada frecuentemente por una segunda línea que define un nivel de significación sugerente (típicamente $P = 10^{-3}$). Cabe destacar que, como se observa en el ejemplo de la Figura 2, si el análisis se realiza bajo metodologías de Tasa de Falsos Descubrimientos (FDR) o paneles de expresión restringidos, dichos umbrales visuales pueden aparecer más relajados que el límite genómico convencional de un GWAS.

Debido a la naturaleza altamente poligénica de los fenotipos psiquiátricos complejos como la tentativa de suicidio, los tamaños de efecto individuales de cada gen, en muchos casos, suelen ser pequeños. Como es costumbre en estudios que utilizan tamaños muestrales moderados, ningún gen logró superar individualmente la severa penalización impuesta por el umbral de Bonferroni.

5.6.3. EXTRACCIÓN DESDE *LOCI* SUGERENTES PARA REVISIÓN BIOLÓGICA

Ante la falta de significación a nivel transcriptómico completo según Bonferroni, la estrategia metodológica se enfocó en los hallazgos sugerentes. Se usó un filtro en R programado para sacar solo los genes que pasaron el umbral de significación sugerente ($TWAS.P < 0.001$).

R

```
top_genes <- twas_data[twas_data$TWAS.P < 0.001, ]  
top_genes <- top_genes[order(top_genes$TWAS.P), ]  
  
write.csv(top_genes, "Top_Genes_Suicidio.csv", row.names = FALSE)
```

Estos genes fueron ordenados de mayor a menor significación y exportados adecuadamente a un archivo tabular (*Top_Genes_Suicidio.csv*). Esta lista de genes *top* constituye el producto final del pipeline analítico y la base sólida para la subsiguiente revisión de la literatura biológica, permitiendo investigar la plausibilidad biológica de estos genes en la neurobiología de la corteza prefrontal dorsolateral y su posible implicación mecanística en el comportamiento suicida.

FUSION recomienda por defecto que el umbral de significación estricto para un estudio TWAS debe calcularse mediante la corrección analítica de Bonferroni para comparaciones múltiples. Este umbral se define como α (nuevo nivel de significancia) = $0.05 / n^\circ$ de genes, donde el número de genes representa el número total de modelos de expresión génica evaluados en el análisis estadístico.

Con todo, la corrección de Bonferroni resulta extremadamente conservadora para contextos de genómica psiquiátrica donde el tamaño muestral del GWAS original es modesto (en este estudio, $N = 5258$). La potencia estadística que falta, debido a este tamaño muestral, eleva la probabilidad de errores de tipo II (falsos negativos) enormemente, descartando señales biológicamente relevantes que no superan el umbral penalizado.

Para compensar esta limitación, se ha diseñado un script computacional en R encargado de procesar y visualizar los resultados analíticos (véase el 9.2). El flujo de trabajo de este algoritmo comienza estableciendo un umbral de significación sugestiva ($P < 0.001$). Luego, se filtran y se extraen de la base de datos únicamente aquellos genes que logran superar dicha marca. A continuación, estos *loci* de interés se ordenan jerárquicamente en función de su significación estadística y se exportan en formato tabular (*Top_Genes_Suicidio.csv*) para facilitar su posterior revisión biológica independiente. Finalmente, el script genera una representación gráfica de los resultados a escala genómica mediante un *Manhattan plot* personalizado. En esta visualización, se omite de manera deliberada la línea de corte estricta de Bonferroni y se traza, en su lugar, una línea indicativa del umbral sugestivo claramente definido. El algoritmo de ploteado etiqueta de manera automática todos los *loci* que sobrepasan este umbral. Esto permite una rápida identificación visual de los genes candidatos, y evita saturar el gráfico con información redundante.

5.7. GUÍA DE INTERPRETACIÓN DE HALLAZGOS

Con el propósito de facilitar la comprensión del diccionario de datos más la direccionalidad de los hallazgos, se detalla la interpretación de uno de los genes que superó el umbral sugestivo en los análisis del trastorno depresivo mayor (*RAB17*, cromosoma 2). Los estadísticos del resultado para este *locus* indicaron lo siguiente:

$$\text{BEST.GWAS.Z} = 4.35$$

$$\text{EQTL.Z} = 10.03$$

$$\text{EQTL.GWAS.Z} = 2.44$$

$$\text{MODEL} = \text{lasso}$$

$$\text{TWAS.Z} = 3.38$$

$$\text{TWAS.P} = 0.000705$$

Este resultado indica que se logró predecir, con mayor precisión, la expresión del gen *RAB17* en el tejido de referencia con la regresión penalizada LASSO. El estadístico principal demostró algo que una mayor expresión predicha genéticamente del gen se asocia de manera positiva con un incremento en el riesgo del fenotipo clínico ($\text{TWAS.Z} = 3.38$; $P < 0.001$). Esta direccionalidad del efecto es consistente con las métricas del mejor polimorfismo regulador (eQTL) de la región, el cual exhibe un fuerte efecto biológico incrementando la expresión del gen ($\text{EQTL.Z} = 10.03$) además de un efecto genético aumentando el riesgo en la cohorte de pacientes ($\text{EQTL.GWAS.Z} = 2.44$).

Para finalizar, se puede llegar a observar que el nivel de significación de la transcripción predicha ($\text{TWAS.Z} = 3.38$) es un nivel ligeramente inferior al pico de riesgo genético crudo de toda esa región cromosómica ($\text{BEST.GWAS.Z} = 4.35$). Esta diferencia señala la necesidad metodológica de ejecutar análisis condicionales posteriores (*joint/conditional tests*) para verificar de manera estadística si la señal del gen es independiente o está explicada por variantes vecinas en LD.

5.8. ANÁLISIS CONDICIONAL DE TWAS Y CONJUNTO DE SEÑALES

Las variantes genéticas tienden a heredarse en bloques conocidos como regiones de desequilibrio de ligamiento (LD) debido a la propia estructura del genoma humano. Esto tiene como

consecuencia que, al hacer un análisis TWAS, varios genes situados en la cerca cromosómicamente puedan reflejar un vínculo estadísticamente relevante con el fenotipo evaluado, aun cuando solo uno de ellos sea el responsable biológicamente de dicho fenotipo. Para discriminar entre las asociaciones transcripcionales verdaderas de aquellas que no son independientes (guiadas únicamente por su proximidad física a un *locus* de riesgo), se implementó un análisis conjunto y condicional utilizando las herramientas de posprocesamiento que ofrece el software FUSION.

Este análisis parte de una premisa estadística basada en la sustracción. Al principio, el algoritmo selecciona a los genes que superan un umbral de significación sugestivo ($P < 0.001$) en el TWAS primario. A continuación, integra las estadísticas resumen del GWAS original. Esto se hace con la matriz de referencia de desequilibrio de ligamiento (LD) de la cohorte europea del Proyecto 1000 Genomas. A través de un modelo matemático, el software evalúa hasta el nivel de significación de los marcadores de riesgo (SNPs) en la región antes y después de condicionar estadísticamente los datos sobre los pesos de expresión predicha del gen candidato. Si tras ajustar por la expresión del gen, el nivel de significación del *locus* disminuye drásticamente (de modo que caiga por debajo del umbral de significancia del genoma) se infiere que dicha alteración transcripcional explica la señal de riesgo genético subyacente. Por otro lado, si la señal del GWAS no se altera tras el condicionamiento, se puede concluir que la asociación del gen en el TWAS se trataba de un falso positivo impulsado por el LD, de modo que se puede entender que la verdadera variante asociada es independiente de la expresión de dicho gen. Este enfoque metodológico resulta indispensable para refinar la lista de candidatos genéticos, así como priorizar aquellos con impacto funcional directo en el fenotipo estudiado.

El método usado para efectuar el análisis conjunto y condicional (*joint/conditional test*) incluyó depurar los datos y solventar las limitaciones técnicas de lectura propias del programa FUSION. Al procesar los resultados completos del TWAS

(*RESULTADOS_TWAS_MDD_COMPLETOS.txt*), se generaron filas con artefactos de texto (la palabra «NA» en lugar de valores nulos reales). Se ejecutó un protocolo de limpieza estricto en el entorno R.

Para solucionar esta inconsistencia, se diseñó e implementó un protocolo de limpieza en el entorno estadístico R. Este proceso consistió en la coerción explícita de las variables genómicas (cromosoma y *p*-valor) a formato numérico, la eliminación de los registros con valores ausentes y el filtrado riguroso de aquellos genes que superaban un umbral de significancia estricto ($P < 0.001$). El conjunto de datos depurado fue exportado a un nuevo directorio bajo el nombre *INPUT_CONDICIONAL_MDD_LIMPIO.txt* para su posterior análisis condicional. El código fuente en R desarrollado para la ejecución de este protocolo se detalla en el anexo (véase 9.3)

Después, se procedió a la fase de análisis genómico en la terminal de Linux (WSL) con el siguiente comando:

```
for chr in {1..22}; do

    echo ">>> Intentando análisis condicional en el cromosoma $chr..."

    Rscript FUSION.post_process.R \

    --sumstats sumstats_MDD_FUSION_FINAL.txt \

    --input INPUT_CONDICIONAL_MDD_LIMPIO.txt \

    --out MDD_POST_ANALYSIS_chr${chr} \

    --ref_ld_chr LDREF/1000G.EUR. \

    --chr $chr \

    --plot \

    --locus_win 100000
```

done

La implementación de este bucle específico permitió automatizar el análisis desde el cromosoma 1 hasta el 22 secuencialmente. Al analizar la estructura del comando, la bandera `--sumstats` incorporó los datos del GWAS original para rastrear el riesgo base de la enfermedad, mientras que `--input` proporcionó nuestra lista de genes candidatos limpio. Además, `--out` definió el prefijo de los archivos resultantes, organizándolos dinámicamente por cromosoma (`_chr${chr}`). Para el cálculo del desequilibrio de ligamiento, `--ref_ld_chr` apuntó hacia los mapas genéticos de la población europea de referencia. Para finalizar, el parámetro `--locus_win 100000` estableció una ventana de exploración de 100 kilobases alrededor del gen candidato con el objetivo de capturar toda la señal genética del vecindario, mientras que el comando `--plot` garantizó la generación automática de los gráficos tipo LocusZoom, permitiendo de esta forma la inspección visual del efecto del condicionamiento sobre la señal de riesgo original de los pacientes.

5.9. ANÁLISIS DE ENRIQUECIMIENTO FUNCIONAL Y VÍAS BIOLÓGICAS

Para trascender el descubrimiento de *loci* individuales y comprender de manera profunda la arquitectura biológica subyacente a nivel de sistemas, se llevó a cabo un análisis de sobrerrepresentación (*over-representation analysis*, ORA). Considerando que la patogénesis de los fenotipos psiquiátricos complejos es mediada por la acción combinada de diversas variantes con tamaños de efecto moderados, se decidió metodológicamente flexibilizar el umbral de significación a un valor nominal de $P < 0.05$. Esta relajación estadística permitió dotar al algoritmo del volumen transcripcional necesario para identificar convergencias en redes biológicas, asumiendo que el ruido estocástico se distribuye de manera aleatoria, mientras que la señal biológica real tiende a agruparse en rutas metabólicas o celulares específicas.

Con el propósito de automatizar y estandarizar la preparación de estos datos, se diseñó un algoritmo de preprocesamiento que se desarrolla en el entorno R (véase el 9.4). El propósito de este script computacional fue actuar como un vínculo de sanitización de datos entre los resultados estadísticos en bruto del TWAS y la plataforma de enriquecimiento. Concretamente, el flujo de trabajo importa la matriz de resultados completos, realiza un estricto control de calidad descartando valores ausentes (NAs) o no numéricos que pudieran corromper el análisis posterior, y además aplica el filtro de significación predefinido. A continuación, el algoritmo aísla de forma exclusiva los identificadores (IDs) de los genes candidatos. Descartando la direccionalidad del estadístico Z , se evalúa la perturbación global de las vías y se exporta una lista plana de texto estrictamente formateada para ser interpretada sin errores de lectura.

Después, se procesaron los conjuntos génicos mediante la plataforma bioinformática Enrichr ([Chen et al., 2013](#)). La sobrerrepresentación funcional se evaluó interrogando dos de las bases de datos más estandarizadas en la literatura genómica. Se usó la Ontología de Procesos Biológicos (GO Biological Process) para determinar las funciones celulares generales, así como la Enciclopedia de Genes y Genomas de Kioto (KEGG Human Pathways) para la identificación de rutas metabólicas y de señalización molecular específicas. La significancia estadística de la sobrerrepresentación de las vías biológicas se calculó mediante una prueba exacta de Fisher, calculada por el propio servidor, y asumiendo un modelo de distribución hipergeométrica sin reemplazo para contrastar la lista de genes de entrada contra el universo total de genes anotados en cada término. Con el objetivo de priorizar los términos enriquecidos, se utilizó la métrica *Combined Score* que es proporcionada por Enrichr. Esta métrica se calcula multiplicando el logaritmo natural del p -valor que se obtiene en la prueba exacta de Fisher por el Z -score que es derivado de la desviación del rango esperado:

$$c = \ln(p) \cdot z$$

Adicionalmente, se reportaron los p -valores bajo significancia nominal ($P < 0.05$) debido a la naturaleza poligénica y exploratoria del estudio.

El análisis se ejecutó con el universo de genes por defecto de la plataforma (el conjunto de genes anotados del genoma). Dado que la lista de entrada procede de un panel restringido de ~5 300 genes con modelo de expresión, el fondo estadísticamente más apropiado habría sido ese mismo panel; el uso del genoma completo como universo tiende a sobrestimar la significación de los enriquecimientos, por lo que los p -valores reportados deben interpretarse en ese marco.

6. RESULTADOS

6.1. OBTENCIÓN DE RESULTADOS DE LOS ANÁLISIS

Este apartado presenta los hallazgos obtenidos tras implementar el flujo de trabajo analítico sobre las estadísticas de resumen genómico para los tres fenotipos psiquiátricos en estudio (trastorno depresivo mayor, trastorno bipolar y tentativa de suicidio). Dada la extrema complejidad de la arquitectura genética asociada a estos rasgos, los resultados se han estructurado siguiendo una progresión lógica en tres fases diferenciadas.

En primer lugar, se exponen los resultados primarios del estudio de asociación del transcriptoma completo (TWAS), identificando las asociaciones iniciales sugestivas. En segundo lugar, se presentan los resultados del análisis conjunto y condicional posterior, un paso matemático fundamental diseñado para evaluar si dichas asociaciones iniciales representan verdaderos moduladores del riesgo (*drivers*) o si son meros artefactos estadísticos arrastrados por el desequilibrio de ligamiento. Finalmente, el tercer bloque aborda el enriquecimiento funcional aplicado a las firmas transcriptómicas (con un valor inferior a $P < 0.05$), trasladando estos hallazgos a un contexto

fisiopatológico mediante la caracterización de las vías celulares alteradas en el tejido de la corteza prefrontal dorsolateral.

6.1.1. RESULTADOS PRIMARIOS DEL ANÁLISIS DE ASOCIACIÓN TRANSCRIPTÓMICA (TWAS)

Como paso previo para hallar los genes más significativos, se ejecutó el *pipeline* principal de asociación transcriptómica utilizando los pesos de expresión del consorcio CommonMind, del tejido de la corteza prefrontal dorsolateral ([Fromer et al., 2016](#)). El algoritmo evaluó con éxito aproximadamente 5300 modelos génicos distribuidos a lo largo de los 22 cromosomas autosómicos. Esta cifra no abarca la totalidad del genoma, sino exclusivamente aquellos genes cuya expresión cerebral demostró ser estadísticamente predecible y heredable en el panel de referencia, omitiendo el resto.

6.1.1.1. EVALUACIÓN GLOBAL A NIVEL DE TRANSCRIPTOMA Y CONTROL DE MULTIPLICIDAD

La visualización genómica de las asociaciones mediante gráficos de Manhattan (*Manhattan plots*) para los tres fenotipos reveló arquitecturas poligénicas consistentes con la literatura psiquiátrica actual ([Smoller et al., 2019](#); [Wray et al., 2018](#)). Al aplicar la corrección analítica de Bonferroni para el control estricto de la tasa de error por familia (FWER), se estableció un umbral de significación genómica de $P < 9.4 \times 10^{-6}$ (calculado como $\alpha = 0.05 / 5300$).

Como es característico en fenotipos de complejidad poligénica analizados bajo tamaños muestrales moderados ($N = 5258$ o 4687 , por ejemplo), ningún *locus* individual logró superar la severa penalización matemática impuesta por el umbral de Bonferroni. Sin embargo, la inspección de las topologías de riesgo identificó varios picos de asociación por encima de la línea de corte para asociaciones sugestivas ($P < 0.001$), que se utilizaron como punto de partida exploratorio para el

análisis condicional posterior. Conviene cuantificar qué cabría esperar bajo la hipótesis nula y qué arroja la corrección por comparaciones múltiples. Si ninguna expresión génica estuviera asociada al fenotipo, los p-valores se distribuirían de forma aproximadamente uniforme en $[0, 1]$, de modo que el número de genes con $TWAS.P < 0,001$ esperado por azar sería de $N \times 0,001 \approx 5\,300 \times 0,001 \approx 5,3$ por fenotipo. El recuento observado fue de 3 genes en MDD, 6 en BD y 7 en SA, de manera que en ningún caso supera de forma estadísticamente significativa lo esperado por azar (siendo incluso inferior a esa expectativa en MDD). De forma concordante, al aplicar la corrección por la tasa de falsos descubrimientos (FDR, Benjamini-Hochberg) ningún gen alcanzó significación en ninguno de los tres fenotipos: el menor valor q correspondió a LOC728323 en BD ($q = 0,14$), mientras que en MDD y SA todos los candidatos presentaron $q \geq 0,37$ (véase en páginas 61, 62 y 63). Es preciso matizar que las pruebas del TWAS no son del todo independientes —los genes de una misma región comparten SNPs y, por tanto, sus estadísticos están correlacionados por el desequilibrio de ligamiento—, por lo que el número efectivo de contrastes es algo menor que 5300; aun así, la conclusión cualitativa se mantiene. En consecuencia, los *loci* que superan el umbral sugestivo deben interpretarse como hipótesis exploratorias a validar, y no como hallazgos establecidos: el diseño, limitado por el tamaño muestral, carece de potencia para distinguir señal real de ruido a este nivel de significación.

6.1.1.2. *LOCI* SUGESTIVOS IDENTIFICADOS POR FENOTIPO CLÍNICO

El filtrado de las estadísticas de resumen permitió aislar las firmas transcriptómicas primarias para cada condición, destacando marcadores con un fuerte tamaño de efecto predictivo (*Z-score*):

- **Trastorno depresivo mayor:** El análisis de la cohorte de depresión mayor arrojó una lista de genes top liderada por la asociación altamente sugestiva del gen *QSOX1* (cromosoma 1). El modelo detectó un fuerte efecto protector, indicando que una mayor expresión genéticamente predicha de *QSOX1* en el tejido prefrontal se asocia con una disminución del

riesgo de padecer la enfermedad ($Z = -3.87$; $P = 0.000109$). En contraposición, en el mismo cromosoma se identificó la señal de *PPM1J* operando como un factor de riesgo transcripcional ($Z = 3.61$; $p = 0.000296$), seguido por el gen *RAB17* en el cromosoma 2 ($Z = 3.38$; $P = 0.000705$). El *Manhattan plot* correspondiente a MDD evidencia gráficamente la prominencia de estos picos sobre el ruido estocástico basal.

Tabla 1. Asociaciones transcriptómicas sugestivas para el trastorno depresivo mayor (MDD).

Gen	Locus (chr : Mb)	Modelo	R ² (CV)	TWAS.Z	TWAS.P	q (FDR)
QSOX1	1 : 180,12	top1	0,041	-3,87	$1,09 \times 10^{-4}$	0,59
PPM1J	1 : 113,25	top1	0,011	+3,62	$2,96 \times 10^{-4}$	0,80
RAB17	2 : 238,48	lasso	0,26	+3,39	$7,05 \times 10^{-4}$	0,99

Nota. Locus: cromosoma y posición de inicio del gen (P0) en Mb. Modelo: método de regresión penalizada (top1 = mejor eQTL único; lasso; enet = Elastic Net; blup; bsimm). R^2_{CV} : precisión predictiva del modelo de expresión por validación cruzada (valores $\leq 0,02$ indican una predicción débil y poco fiable). TWAS.Z / TWAS.P: estadístico y p-valor de la asociación (signo positivo = mayor expresión predicha asociada a mayor riesgo; negativo = efecto protector). q (FDR): p-valor corregido por Benjamini-Hochberg. Ningún gen alcanza significación tras la corrección.




Figura 3. Gráfico de Manhattan de las asociaciones transcriptómicas para el trastorno depresivo mayor.

El eje de abscisas representa la posición física en los 22 autosomas y el eje de ordenadas muestra el nivel de significación estadística ($-\log_{10} P$). La línea azul continua indica el umbral de asociación sugestiva ($P < 0.001$). **Fuente:** elaboración propia.

• **Trastorno bipolar:** La evaluación del fenotipo bipolar consolidó un catálogo de genes sugestivos que cruzaron el umbral exploratorio de $P < 0.001$. Estos fueron *PARK7*, *CRB1*, *LOC728323*, *PCGF3*, *FAM21C* y *SLMO1*. Al igual que en las condiciones anteriores, la gráfica de Manhattan para BD documentó cómo estas asociaciones emergen en distintos cromosomas, reflejando la dispersión del riesgo poligénico.

Tabla 2. Asociaciones transcriptómicas sugestivas para el trastorno bipolar (BD).

Gen	Locus (chr : Mb)	Modelo	R ² (CV)	TWAS.Z	TWAS.P	q (FDR)
<i>LOC728323</i>	2 : 243,03	blup	0,071	-4,21	$2,51 \times 10^{-5}$	0,14
<i>CRB1</i>	1 : 197,17	blup	0,015	-3,75	$1,76 \times 10^{-4}$	0,47
<i>SLMO1</i>	18 : 12,41	lasso	0,23	+3,54	$3,96 \times 10^{-4}$	0,62
<i>PARK7</i>	1 : 8,02	bslmm	0,012	-3,50	$4,61 \times 10^{-4}$	0,62
<i>FAM21C</i>	10 : 46,22	bslmm	0,11	-3,35	$8,17 \times 10^{-4}$	0,73
<i>PCGF3</i>	4 : 0,70	enet	0,060	-3,33	$8,82 \times 10^{-4}$	0,73




Figura 4. Gráfico de Manhattan de las asociaciones transcriptómicas para el trastorno bipolar.

Distribución cromosómica de las asociaciones del TWAS. Los marcadores por encima de la línea azul continua representan aquellos loci que superan el umbral de significación sugestiva ($P < 0.001$). Fuente: elaboración propia.

- Tentativa de suicidio:** La predicción transcriptómica para la conducta suicida aisló señales de alto interés biológico. Los genes detectados fueron *QSOX1*, *ESR1*, *ABCB8*, *ANKRD18A*, *RSUI*, *POLI* y *CD93*. La asociación con menor p -valor se localizó en el cromosoma 20, sobre el gen *CD93* ($Z = 3.87$; $p = 0.000108$), donde una mayor expresión predicha se asoció con un mayor riesgo. No obstante, conviene advertir que el modelo de expresión de *CD93* es de muy baja calidad predictiva ($R^2_{CV} = 0.01$) y que su mejor eQTL carece de asociación con el fenotipo (EQTL.GWAS. $Z = -0.25$), por lo que esta señal debe interpretarse con especial cautela pese a presentar el menor p -valor. De forma paralela, el gen *ESR1* (Receptor 1 de estrógeno; cromosoma 6) exhibió una asociación de magnitud prácticamente idéntica ($Z = 3.81$; $P = 0.000137$) sustentada en un modelo de expresión más fiable ($R^2_{CV} = 0.10$; Tabla 3).

Tabla 3. Asociaciones transcriptómicas sugestivas para la tentativa de suicidio (SA).

Gen	Locus (chr : Mb)	Modelo	R ² (CV)	TWAS.Z	TWAS.P	q (FDR)
CD93	20 : 23,06	bslmm	0.010	+3.87	1.08×10^{-4}	0.37
ESR1	6 : 152,01	enet	0.10	+3.81	1.37×10^{-4}	0.37
POLI	18 : 51,80	lasso	0.32	-3.57	3.56×10^{-4}	0.51
RSU1	10 : 16,63	enet	0.14	-3.52	4.29×10^{-4}	0.51
ANKRD18A	9 : 38,57	lasso	0.21	-3.50	4.73×10^{-4}	0.51
ABCB8	7 : 150,73	bslmm	0.18	-3.42	6.36×10^{-4}	0.57
QSOX1	1 : 180,12	top1	0.041	-3.37	7.54×10^{-4}	0.58

Nota. Locus: cromosoma y posición de inicio del gen (P0) en Mb. Modelo: método de regresión penalizada (top1 = mejor eQTL único; lasso; enet = Elastic Net; blup; bslmm). R² (CV): precisión predictiva del modelo de expresión por validación cruzada (valores $\leq 0,02$ indican una predicción débil y poco fiable). TWAS.Z / TWAS.P: estadístico y p-valor de la asociación (signo positivo = mayor expresión predicha asociada a mayor riesgo; negativo = efecto protector). q (FDR): p-valor corregido por Benjamini-Hochberg. Ningún gen alcanza significación tras la corrección.

TWAS: Tentativa de suicidio y expresión en corteza prefrontal dorsolateral




Figura 5. Gráfico de Manhattan de las asociaciones transcriptómicas para la tentativa de suicidio.

Distribución cromosómica de las asociaciones del TWAS. Los marcadores por encima de la línea azul continua representan aquellos loci que superan el umbral de significación sugestiva ($P < 0.001$). **Fuente:** elaboración propia.

La identificación exitosa de estos *loci* sugestivos constituyó el producto final del TWAS primario. No obstante, superar este umbral estadístico no garantiza que la alteración en la expresión de estos genes esté asociada con los trastornos (en el caso de la depresión mayor y el trastorno bipolar) o el comportamiento clínico (en el caso de la tentativa de suicidio). Debido a la propia estructura del genoma humano, las variantes genéticas tienden a heredarse en grandes bloques, un fenómeno conocido como desequilibrio de ligamiento (LD). Esto provoca que un gen pueda mostrar una fuerte asociación estadística simplemente por ser «vecino» físico del verdadero gen responsable, arrastrando su señal sin tener un papel funcional real. Por este motivo, para diferenciar las asociaciones biológicamente genuinas de los simples artefactos de proximidad genómica, fue primordial someter esta lista de candidatos a un análisis estadístico condicional (*joint/conditional test*).

6.1.2. RESULTADOS COMPLETOS DEL ANÁLISIS CONJUNTO CONDICIONAL

Como se mencionaba anteriormente, la identificación inicial de asociaciones genéticas significativas en un análisis TWAS es un primer paso importante, pero no garantiza, por sí sola, una relación de causalidad primaria. De hecho, tampoco lo hace el análisis condicional que se presenta a continuación, puesto que para ello se requeriría una validación experimental *in vitro* o *in vivo*. Sin embargo, este análisis condicional sí que pretende priorizar estadísticamente aquellos genes candidatos cuya expresión predicha explica la señal del GWAS de forma independiente, separándolos de los simples artefactos inducidos por la proximidad genómica.

La intrincada topología del genoma da lugar a situaciones en las que múltiples genes pueden manifestar una fuerte significación estadística. Esto ocurre por el hecho de coheredar junto a una variante verdaderamente asociada y vecina, un fenómeno inherente al desequilibrio de ligamiento

(LD). Por consiguiente, antes de proceder a la evaluación de vías biológicas, conviene realizar un escrutinio de validación a través del *fine-mapping* transcripcional o análisis condicional.

Los resultados expuestos a continuación detallan el comportamiento topológico de la señal de riesgo genético subyacente. Esta señal es derivada del GWAS original y se somete a un condicionamiento matemático basado en la expresión predicha de los genes sugerentes. El análisis evalúa, para cada región, si los genes sugestivos representan señales independientes o si alguno es redundante por desequilibrio de ligamiento con otro candidato. A continuación, se desglosan los resultados por fenotipo clínico en la Tabla 4.

Tabla 4. Resultados del análisis conjunto y condicional (joint/conditional test de FUSION) para los genes sugestivos de los tres fenotipos (MDD, BD y SA).

Fenotipo	Gen	Crom.	TWAS.Z	TWAS.P	JOINT.Z	JOINT.P	Resultado
MDD	QSOX1	1	-3.87	1.09×10^{-4}	-3.87	1.09×10^{-4}	Independiente
MDD	PPM1J	1	+3.62	2.96×10^{-4}	+3.62	2.96×10^{-4}	Independiente
MDD	RAB17	2	+3.39	7.05×10^{-4}	+3.39	7.05×10^{-4}	Independiente
BD	LOC728323	2	-4.21	2.51×10^{-5}	-4.21	2.51×10^{-5}	Independiente
BD	CRB1	1	-3.75	1.76×10^{-4}	-3.75	1.76×10^{-4}	Independiente
BD	SLMO1	18	+3.54	3.96×10^{-4}	+3.54	3.96×10^{-4}	Independiente
BD	PARK7	1	-3.50	4.61×10^{-4}	-3.50	4.61×10^{-4}	Independiente
BD	FAM21C	10	-3.35	8.17×10^{-4}	-3.35	8.17×10^{-4}	Independiente
BD	PCGF3	4	-3.33	8.82×10^{-4}	-3.33	8.82×10^{-4}	Independiente
SA	CD93	20	+3.87	1.08×10^{-4}	+3.87	1.08×10^{-4}	Independiente
SA	ESR1	6	+3.81	1.37×10^{-4}	+3.81	1.37×10^{-4}	Independiente
SA	POLI	18	-3.57	3.56×10^{-4}	-3.57	3.56×10^{-4}	Independiente
SA	RSU1	10	-3.52	4.29×10^{-4}	-3.52	4.29×10^{-4}	Independiente
SA	ANKRD18A	9	-3.50	4.73×10^{-4}	-3.50	4.73×10^{-4}	Independiente
SA	ABCB8	7	-3.42	6.36×10^{-4}	-3.42	6.36×10^{-4}	Independiente

Fenotipo	Gen	Crom.	TWAS.Z	TWAS.P	JOINT.Z	JOINT.P	Resultado
SA	QSOX1	1	-3.37	7.54×10^{-4}	-3.37	7.54×10^{-4}	Independiente

Nota. TWAS.Z / TWAS.P: estadístico marginal de cada gen. JOINT.Z / JOINT.P: estadístico del modelo conjunto (*joint/conditional test* de FUSION). «Independiente» = gen incluido en el modelo conjunto (archivo *joint_included*); ningún gen fue descartado (*joint_dropped* vacío) en ninguno de los tres fenotipos. En todos los genes JOINT = TWAS, lo que indica que el condicionamiento no atenuó ninguna señal: ninguna asociación es un artefacto de desequilibrio de ligamiento con otro candidato.

6.1.2.1. RESULTADOS DEL ANÁLISIS CONJUNTO Y CONDICIONAL PARA LA DEPRESIÓN MAYOR (MDD)

Con el fin de evaluar si las asociaciones transcripcionales sugestivas ($P < 0.001$) identificadas en la corteza prefrontal dorsolateral estaban guiadas por verdaderos efectos de expresión genética o constituían asociaciones no independientes debidas al desequilibrio de ligamiento (LD) con variantes causales cercanas, se realizó un análisis condicional a partir de la señal del GWAS (*joint/conditional test*). La evaluación de los loci sugestivos se resume a continuación.

El análisis conjunto y condicional (*joint/conditional test*) evaluó si los genes sugestivos representan señales independientes o si alguno es redundante por LD con otro candidato cercano. En el trastorno depresivo mayor, los tres genes sugestivos resultaron señales independientes: los tres quedaron incluidos en el modelo conjunto (*joint_included*) y ninguno fue descartado (*joint_dropped* vacío), con un estadístico conjunto idéntico al marginal ($JOINT.Z = TWAS.Z$; Tabla 4). Esto es coherente con que los candidatos se localizan en posiciones muy distantes (*QSOX1* y *PPM1J* en el cromosoma 1, separados ~67 Mb, y *RAB17* en el cromosoma 2) y no comparten bloques de LD. Por tanto, el análisis no identificó ningún falso positivo por desequilibrio de ligamiento entre los candidatos de este fenotipo.




Figura 6. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen *QSOX1* en el contexto de la depresión mayor.

Se contrastan los *p*-valores originales del GWAS (puntos grises) frente a los *p*-valores residuales tras condicionar la señal sobre la expresión predicha de *QSOX1* (puntos azules) en el tejido DLPFC. *QSOX1* constituye una señal transcripcional independiente (incluida en el modelo conjunto; Tabla 4); su menor atenuación visible es coherente con la modesta precisión de su modelo de expresión ($R^2_{CV} = 0.04$) y no implica que sea un artefacto de LD. **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

Un patrón distinto se observó en un segundo *locus* situado también en el cromosoma 1, observable en la Figura 7. Al analizar el pico de riesgo genómico localizado en torno a las 113.0 Mb, se identificó el gen *PPMIJ* como un candidato funcional de alta prioridad. La señal cruda del GWAS presentaba en esta ventana una asociación notable ($-\log_{10} P > 3.5$) que, tras el condicionamiento sobre la expresión predicha de *PPMIJ* en la corteza prefrontal dorsolateral, colapsó por completo hasta niveles basales. El grado de atenuación visible en este *locus* depende de la precisión del modelo de expresión y, como el resto de candidatos, *PPMIJ* constituye una señal transcripcional independiente (Tabla 4), sin que ello implique causalidad.




Figura 7. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen PPM1J en MDD.

Los puntos grises representan la señal cruda del GWAS y los puntos azules la señal residual tras condicionar sobre la expresión de PPM1J. Se observa un colapso completo del pico de asociación original (cromosoma 1, ~113.0 MB). El gráfico ilustra el condicionamiento de la señal del GWAS sobre la expresión predicha de PPM1J; el gen constituye una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

Resultados análogos de conducción funcional se obtuvieron en el cromosoma 2, específicamente en relación con el *locus* del gen *RAB17* (Figura 8), el cual evidenciaba una fuerte señal de riesgo pleiotrópica. Al condicionar estadísticamente la señal del GWAS utilizando los pesos de expresión de *RAB17*, el pico de asociación genómica original (situado en torno a las 238.5 Mb con un $-\log_{10} P \approx 5$) quedó atenuado casi en su totalidad, reduciéndose drásticamente la significación de las variantes residuales. Este hallazgo postula a *RAB17* como otro candidato funcional exploratorio en el tejido cerebral para este fenotipo.




Figura 8. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen RAB17 en MDD.

La señal original del GWAS (puntos grises) muestra un pico significativo (cromosoma 2, ~238.5 Mb) que se atenúa sustancialmente al condicionar sobre la expresión de RAB17 (puntos azules). RAB17 constituye una señal transcripcional independiente (Tabla 4); el grado de atenuación visible depende de la precisión de su modelo ($R^2_{CV} = 0.26$). **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

En conjunto, el análisis conjunto y condicional indica que las tres asociaciones sugestivas del trastorno depresivo mayor (*QSOX1*, *PPMIJ* y *RAB17*) son señales transcripcionales mutuamente independientes, sin redundancia atribuible al desequilibrio de ligamiento. No obstante, esta independencia espacial no equivale a causalidad ni a significación estadística: ninguno de los tres genes supera la corrección por comparaciones múltiples ($q \geq 0.59$; Tabla 1), por lo que deben considerarse candidatos exploratorios y no dianas validadas.

6.1.2.2. RESULTADOS DEL ANÁLISIS CONJUNTO Y CONDICIONAL PARA EL TRASTORNO BIPOLAR (BD) EN LA CORTEZA PREFRONTAL DORSOLATERAL (DLPFC)

A fin de dilucidar si las asociaciones transcriptómicas sugerentes halladas en el tejido prefrontal (DLPFC) para el trastorno bipolar constituían señales funcionales auténticas o solo artefactos estadísticos derivados del desequilibrio de ligamiento (LD), se procedió a la evaluación

analítica mediante gráficos de tipo LocusZoom condicionales. El escrutinio de los seis *loci* identificados se detalla en el siguiente apartado.

El análisis conjunto/condicional de los seis genes sugestivos del trastorno bipolar mostró que todos constituyen señales transcripcionales independientes: los seis quedaron incluidos en el modelo conjunto y ninguno fue descartado ($\text{JOINT.Z} = \text{TWAS.Z}$ en todos los casos; Tabla 4). Este resultado refleja que los candidatos se distribuyen en posiciones muy distantes del genoma (cromosomas 1, 2, 4, 10 y 18) y no comparten bloques de disequilibrio de ligamiento, de modo que condicionar unos sobre otros no altera su significación. En consecuencia, el análisis no identificó ningún falso positivo por LD entre los candidatos de este fenotipo. Las Figuras 9 a 14 ilustran, para cada gen, el condicionamiento de la señal del GWAS regional sobre su expresión predicha; el grado de atenuación visible varía entre genes y depende en buena medida de la precisión de cada modelo de expresión (Tabla 2), no de una distinción entre conductores y artefactos.




Figura 9. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen FAM21C (cromosoma 10) en el trastorno bipolar.

Se contrastan los p-valores originales del GWAS (puntos grises) frente a los p-valores residuales tras condicionar la señal (puntos azules). FAM21C constituye una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

TÍTULO DEL TFG: Estudio de asociación del transcriptoma completo y análisis integrativo en corteza prefrontal para depresión mayor, trastorno bipolar y tentativa de suicidio




Figura 10. Gráfico LocusZoom condicional para el locus del gen *PCGF3* (cromosoma 4) en el trastorno bipolar.

PCGF3 constituye una señal transcripcional independiente (Tabla 4); no se identificó redundancia por LD con ningún otro candidato.

Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 11. Gráfico LocusZoom condicional para el locus de *LOC728323* (cromosoma 2) en el trastorno bipolar.

Se observa un colapso casi total de la pronunciada señal original del GWAS (puntos grises) tras condicionar sobre la expresión de *LOC728323* (puntos azules). Conforma una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

En el cromosoma 1 (Figura 12), la evaluación del gen *PARK7* mostró una atenuación visible: la señal original del GWAS, que alcanzaba un $-\log_{10} P = 2.5$, se redujo a niveles basales (por debajo de 1.0) al condicionar sobre su expresión. Como el resto de los candidatos, *PARK7* constituye una señal transcripcional independiente (Tabla 4).




Figura 12. Gráfico LocusZoom condicional para el locus del gen *PARK7* (cromosoma 1) en el trastorno bipolar.

La señal de riesgo original se atenúa hasta niveles basales tras el condicionamiento, *PARK7* constituye una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de FUSION.

Como se puede observar en la Figura 13, en este mismo cromosoma 1, el locus del gen *CRB1* presentó un comportamiento análogo: la señal genómica original situada por encima de 3.0 experimentó una caída tras el condicionamiento transcriptómico. *CRB1* es igualmente una señal transcripcional independiente (Tabla 4).




Figura 13. Gráfico LocusZoom condicional para el locus del gen *CRB1* (cromosoma 1) en el trastorno bipolar.

CRB1 constituye una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de *FUSION*.

Finalmente, patrones similares se documentaron en el cromosoma 18, hallable en la Figura 14. Al evaluar la región condicionando sobre los pesos de expresión del gen *SLMO1*, el pico principal de asociación sufrió una atenuación representativa. En conjunto, los seis genes sugestivos del trastorno bipolar (*LOC728323*, *CRB1*, *SLMO1*, *PARK7*, *FAM21C* y *PCGF3*) constituyen señales transcripcionales mutuamente independientes. Esta independencia no implica causalidad ni significación: ninguno supera la corrección por comparaciones múltiples ($q \geq 0.14$; Tabla 2), por lo que deben tratarse como candidatos exploratorios.




Figura 14. Gráfico LocusZoom condicional para el locus del gen *SLMO1* (cromosoma 18) en el trastorno bipolar.

SLMO1 constituye una señal transcripcional independiente (Tabla 4). **Fuente:** Elaboración propia a partir de datos del análisis condicional de *FUSION*.

6.1.2.3. RESULTADOS DEL ANÁLISIS CONJUNTO Y CONDICIONAL PARA TENTATIVA DE SUICIDIO (SA) EN CORTEZA PREFRONTAL DORSOLATERAL (DLPFC)

Con el fin de investigar la potencial causalidad funcional de los genes que excedieron el límite de asociación sugestiva en el fenotipo de tentativa de suicidio, se aplicó el análisis de asociación condicional y conjunta (*joint/conditional test*) a partir de la señal del GWAS. A diferencia de evaluaciones previas, el análisis conjunto/condicional evaluó si los genes sugestivos representan señales independientes o si alguno es redundante por desequilibrio de ligamiento con otro candidato. A continuación, se exponen los resultados.

El análisis conjunto/condicional de los siete genes sugestivos de la tentativa de suicidio mostró que todos constituyen señales transcripcionales independientes: los siete quedaron incluidos en el modelo conjunto y ninguno fue descartado ($JOINT.Z = TWAS.Z$ en todos los casos; Tabla 4). Como en los otros dos fenotipos, los candidatos se localizan en cromosomas distintos (1, 6, 7, 9, 10, 18 y 20) y no comparten bloques de desequilibrio de ligamiento, de modo que el condicionamiento no modifica su significación; el análisis no identificó ningún falso positivo por LD. Las figuras de la 15

a la 21 ilustran, para cada gen, el condicionamiento de la señal del GWAS regional sobre su expresión predicha; el grado de atenuación visible depende de la precisión de cada modelo de expresión (R_{CV}^2 ; Tabla 3), no de una distinción entre conductores y artefactos. En particular, conviene advertir que CD93, pese a presentar el menor p -valor, se sustenta en un modelo de expresión de muy baja calidad ($R_{CV}^2 = 0.01$) y en un eQTL sin asociación con el fenotipo (EQTL.GWAS.Z = -0.25), por lo que es el candidato menos fiable.




Figura 15. Gráfico LocusZoom condicional del análisis FUSION para el locus del gen ESR1 (cromosoma 6) en tentativa de suicidio.

Los p -valores originales del GWAS (puntos grises) y los residuales tras el condicionamiento sobre ESR1 (puntos azules) muestran un solapamiento exacto. ESR1 constituye una señal transcripcional independiente (Tabla 4); su menor atenuación visible no implica un artefacto de LD. Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.

TÍTULO DEL TFG: Estudio de asociación del transcriptoma completo y análisis integrativo en corteza prefrontal para depresión mayor, trastorno bipolar y tentativa de suicidio




Figura 16. Gráfico LocusZoom condicional para el locus del gen ABCB8 (cromosoma 7) en SA.

La señal genómica residual (azul) traza fielmente la topología de la señal cruda (gris), ABCB8 constituye una señal transcripcional independiente (Tabla 4). Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 17. Gráfico LocusZoom condicional para el locus del gen QSOX1 (cromosoma 1) en SA.

El análisis corrobora el perfil señal transcripcional independiente, persistiendo el riesgo genético subyacente. Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 18. Gráfico LocusZoom condicional para el locus del gen *RSU1* (cromosoma 10) en SA.

RSU1 constituye una señal transcripcional independiente (Tabla 4). Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 19. Gráfico LocusZoom condicional para el locus del gen *POLI* (cromosoma 18) en la tentativa de suicidio.

Se documenta un colapso masivo de la prominente señal original del GWAS (puntos grises) tras condicionar sobre la expresión de *POLI* (puntos azules). *POLI* constituye una señal transcripcional independiente (Tabla 4); el grado de atenuación depende de la precisión de su modelo ($R^2_{CV} = 0.32$). Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 20. Gráfico LocusZoom condicional para el locus del gen ANKRD18A (cromosoma 9) en SA.

ANKRD18A constituye una señal transcripcional independiente (Tabla 4). Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.




Figura 21. Gráfico LocusZoom condicional para el locus del gen CD93 (cromosoma 20) en SA.

CD93 constituye una señal transcripcional independiente (Tabla 4); su modelo de expresión es de baja fiabilidad ($R^2_{CV} = 0.01$). Fuente: Elaboración propia a partir de datos del análisis condicional de FUSION.

En síntesis, los siete genes sugestivos de la tentativa de suicidio (*CD93*, *ESR1*, *POLI*, *RSU1*, *ANKRD18A*, *ABCB8* y *QSOX1*) constituyen señales transcripcionales mutuamente independientes, sin que ninguno se comporte como artefacto de desequilibrio de ligamiento con otro candidato. No

obstante, esta independencia no implica causalidad ni significación: ninguno supera la corrección por comparaciones múltiples ($q \geq 0.37$; Tabla 3), por lo que deben considerarse candidatos exploratorios.

6.1.3. RESULTADOS DEL ENRIQUECIMIENTO FUNCIONAL

Para la realización de este análisis, tanto para MDD, como BD y SA, se filtraron aquellos genes que contaban con un p -valor inferior a 0.05. Dichos genes fueron ordenados en una lista A partir de la cual se identificaron perfiles de sobrerrepresentación funcional diferenciados para cada uno de los fenotipos psiquiátricos. Para la visualización e interpretación estandarizada de estos perfiles, se extrajeron los gráficos de barras generados directamente por el motor analítico de la plataforma Enrichr. En estas representaciones, la longitud de cada barra es directamente proporcional al nivel de significación estadística del término enriquecido, expresado como el $-\log_{10} P$, siendo P el p -valor.

6.1.3.1. TRASTORNO DEPRESIVO MAYOR

Como se presenta en la Figura 22 la evaluación de los procesos biológicos (GO Biological Process) reveló que la lista de genes asociada a MDD presenta un enriquecimiento nominal significativo en procesos vinculados a la adhesión celular dependiente de calcio y el catabolismo de la galactosa.




Figura 22. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos en el trastorno depresivo mayor.

La prominencia de la adhesión celular dependiente de calcio sugiere una alteración constitutiva en los mecanismos de andamiaje y plasticidad celular en el tejido DLPFC. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

De forma paralela, el análisis de rutas de señalización específicas (KEGG) destacó una sobrerrepresentación de genes involucrados en la vía de señalización de la insulina, así como en la cascada de señalización de mTOR, ambas de fundamental importancia en el metabolismo celular y la plasticidad sináptica (Figura 23).




Figura 23. Gráfico de barras de rutas de señalización (KEGG Human Pathways) enriquecidas en el trastorno depresivo mayor.

La identificación de las vías de la insulina y mTOR señala una potencial desregulación en la homeostasis metabólica y la supervivencia celular. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

6.1.3.2. TRASTORNO BIPOLAR

En el fenotipo BD, la ontología de procesos biológicos (GO Biological Process) mostró una fuerte señal en importantes procesos celulares dinámicos; las vías que presentaron mayor significancia nominal incluyeron la respuesta celular a determinados estímulos hormonales, la regulación del proceso de endocitosis de vesículas sinápticas y la respuesta al estrés oxidativo. (Véase la Figura 24)




Figura 24. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos en el trastorno bipolar.

La sobrevaluación de la endocitosis de vesículas sinápticas y la respuesta a estímulos hormonales apunta a disfunciones en la neurotransmisión y la reactividad celular. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

La interrogación de la base de datos KEGG, por su parte, evidenció un enriquecimiento en la biosíntesis de glucosaminoglicanos y confirmó un aumento de glucoesfingolípidos, componentes clave en la estructura, soporte y señalización de la membrana neuronal (Figura 25)




Figura 25. Gráfico de barras de rutas moleculares (KEGG Human Pathways) enriquecidas en el trastorno bipolar.

La alteración en las vías de glucosaminoglicanos y glucoesfingolípidos subraya la relevancia de la integridad lipídica y estructural de las membranas en la fisiopatología celular. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

6.1.3.3. TENTATIVA DE SUICIDIO

Finalmente, los genes relacionados con la tentativa de suicidio trazaron un perfil funcional centrado en la homeostasis y el mantenimiento estructural a nivel subcelular. El análisis mediante GO Biological Process destacó en los primeros rangos la regulación del ensamblaje de complejos proteicos, así como la fusión autofagosoma-lisosoma (Figura 26).




Figura 26. Gráfico de barras de procesos biológicos (GO Biological Process) enriquecidos para el fenotipo de tentativa de suicidio.

La implicación de procesos de autofagia y ensamblaje proteico refleja posibles anomalías en las rutas de degradación, aclaramiento celular y mantenimiento macromolecular. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

El cruce con la base de datos KEGG reveló asociaciones estadísticamente sugestivas con la ruta de la Anemia de Fanconi, una vía crítica implicada en la reparación del ADN, además de destacar el metabolismo de compuestos de un carbono mediado por folato (Figura 27)




Figura 27. Gráfico de barras de rutas metabólicas y de reparación (KEGG Human Pathways) enriquecidas para el fenotipo de tentativa de suicidio.

La presencia de rutas de reparación de daños en el ADN sugiere una vulnerabilidad celular intrínseca frente al estrés genotóxico en conductas suicidas. **Fuente:** Elaboración propia a partir de resultados analíticos de la plataforma Enrichr.

7. CONCLUSIONES

El presente trabajo ha abordado, desde una perspectiva bioinformática integrativa, la arquitectura transcriptómica del riesgo genético en tres fenotipos psiquiátricos complejos: el trastorno depresivo mayor (MDD), el trastorno bipolar (BD) y la tentativa de suicidio (SA). A partir del despliegue de un flujo de trabajo computacional completo —que ha abarcado desde el preprocesamiento de estadísticas de resumen genómicas hasta la ejecución de análisis de enriquecimiento funcional, pasando por el TWAS primario y el *fine-mapping* transcripcional mediante pruebas condicionales— es posible extraer un conjunto de conclusiones que responden de forma directa a los objetivos planteados.

7.1. SOBRE EL OBJETIVO METODOLÓGICO: LA VIABILIDAD DEL PIPELINE Y LA FORTALEZA DEL ENFOQUE TRANSCRIPTÓMICO HEREDITARIO

El primer logro del trabajo ha sido la implementación exitosa de un pipeline TWAS completo sobre datos genómicos reales procedentes de investigación activa. La armonización rigurosa de las estadísticas de resumen, incluyendo el filtrado de valores ausentes, la exclusión de *Odds Ratios* inválidos y el cálculo matemático de *Z-scores* normalizados mediante la transformación logarítmica del OR dividida por el error estándar, ha demostrado ser una etapa crítica e indispensable para garantizar la integridad analítica posterior. La validación del pipeline sobre el cromosoma 22 —con un 0 % de genes omitidos— confirmó la solidez del procesamiento previo y habilitó el escalado al genoma completo con plenas garantías metodológicas.

Más allá del logro técnico, conviene destacar la fortaleza conceptual del enfoque adoptado. A diferencia de los estudios de expresión diferencial fáctica —en los que los niveles de ARNm observados en una muestra clínica pueden estar profundamente confundidos por factores ambientales, el estado clínico del paciente, los tratamientos farmacológicos recibidos o el propio efecto de la enfermedad sobre el transcriptoma (el denominado problema de la causalidad inversa)— el TWAS

cuantifica el componente de la expresión génica que está constitucionalmente inscrito en el ADN del individuo desde su concepción. Al tratarse de un predictor genético inherente, este enfoque reduce el riesgo de causalidad inversa: en la medida en que las asociaciones sean reales, informarían sobre la predisposición biológica estructural al riesgo psiquiátrico, y no sobre una consecuencia del trastorno. Esta distinción es relevante, ya que el componente genético de la expresión queda fijado desde la concepción y, por tanto, precede al fenotipo clínico, un requisito necesario, aunque no suficiente, para la inferencia causal.

7.2. SOBRE EL OBJETIVO PRIMARIO DEL TWAS: IDENTIFICACIÓN DE *LOCI* CON ASOCIACIÓN SUGESTIVA

El análisis de asociación transcriptómica evaluó con éxito aproximadamente 5.300 modelos génicos en la corteza prefrontal dorsolateral (DLPFC). En consonancia con lo esperado para fenotipos psiquiátricos de naturaleza altamente poligénica analizados en cohortes de tamaño muestral moderado, ningún gen superó el umbral de significación genómica estricto de Bonferroni ($P < 9.4 \times 10^{-6}$) en ninguno de los tres fenotipos. Este resultado no debe interpretarse como ausencia de señal biológica. La corrección de Bonferroni, diseñada para controlar la tasa de error de tipo I, impone una penalización tan severa que, en estudios con las dimensiones muestrales de este trabajo, genera inevitablemente una tasa excesiva de errores de tipo II, descartando señales biológicamente plausibles. En este contexto, los *loci* que superaron el umbral de asociación sugestiva ($P < 0.001$) constituyen únicamente un conjunto de candidatos exploratorios. Como se detalla en [6.1.1.1](#), su número no excede de forma significativa el esperado por azar dado el número de genes contrastados, por lo que no puede concluirse que reflejen señal biológica establecida; deben entenderse como hipótesis a contrastar en cohortes de mayor tamaño. Con la cautela que impone el tamaño muestral, lo que sí permite afirmar este trabajo es que el *pipeline* implementado genera y prioriza tales hipótesis de forma reproducible y metodológicamente coherente.

7.3. SOBRE EL ANÁLISIS CONDICIONAL: INDEPENDENCIA DE LAS SEÑALES SUGESTIVAS

El análisis conjunto y condicional es un paso imprescindible en cualquier TWAS riguroso, pues permite evaluar si las señales sugestivas son independientes o si alguna es redundante por desequilibrio de ligamiento con otro candidato. En este trabajo, su aplicación a los tres fenotipos arrojó un resultado homogéneo, que se detalla a continuación.

En el trastorno depresivo mayor, el análisis conjunto y condicional mostró que los tres genes sugestivos (*QSOX1*, *PPMIJ* y *RAB17*) son señales transcripcionales independientes: todos quedaron incluidos en el modelo conjunto y ninguno fue descartado por desequilibrio de ligamiento ($\text{JOINT.Z} = \text{TWAS.Z}$; Tabla 4). *PPMIJ* (proteína fosfatasa de tipo 2C) y *RAB17* (GTPasa del tráfico vesicular), junto con *QSOX1*, emergen como candidatos exploratorios. Esta independencia no equivale a causalidad ni a significación estadística ($q \geq 0.59$).

En el trastorno bipolar, los seis genes sugestivos (*LOC728323*, *CRBI*, *SLMO1*, *PARK7*, *FAM21C* y *PCGF3*) resultaron señales transcripcionales independientes en el análisis conjunto, sin que ninguno fuera descartado por desequilibrio de ligamiento (Tabla 4). De entre ellos, *PARK7* (DJ-1), con función neuroprotectora frente al estrés oxidativo, posee una plausibilidad biológica destacable. Como en el resto del estudio, ninguno alcanza significación tras corrección ($q \geq 0.14$), por lo que deben considerarse candidatos exploratorios.

En el fenotipo de la tentativa de suicidio, el análisis conjunto/condicional mostró que los siete genes sugestivos (*CD93*, *ESR1*, *POLI*, *RSU1*, *ANKRD18A*, *ABCB8* y *QSOX1*) son señales transcripcionales independientes: todos quedaron incluidos en el modelo conjunto y ninguno fue descartado por desequilibrio de ligamiento (Tabla 4). Entre ellos, *POLI* (ADN polimerasa iota), implicada en la reparación del ADN, resulta de interés por su coherencia con las vías de respuesta al daño genotóxico señaladas en el enriquecimiento. Conviene matizar que *CD93*, el de menor p-valor,

se apoya en un modelo de expresión poco fiable ($R_{CV}^2 = 0.01$). Como en el resto del estudio, ninguna de estas señales alcanza significación tras corrección ($q \geq 0.37$), por lo que deben tratarse como candidatos exploratorios.

7.4. SOBRE EL ENRIQUECIMIENTO FUNCIONAL: CONVERGENCIA BIOLÓGICA Y RUTAS DE SEÑALIZACIÓN RELEVANTES

El análisis de sobrerrepresentación aplicado a las listas de genes candidatos con asociación nominal ($P < 0.05$) ha permitido trasladar los hallazgos individuales a un contexto de redes y rutas biológicas, aportando una dimensión fisiopatológica que complementa y enriquece la interpretación de los resultados. Aunque la naturaleza exploratoria de este análisis impide extraer conclusiones definitivas, los enriquecimientos identificados son coherentes con la neurobiología conocida de los tres fenotipos y generan hipótesis de investigación con plausibilidad mecanicista.

Es importante subrayar tres cautelas. En primer lugar, el análisis se realizó sobre listas de genes con asociación nominal ($P < 0.05$), un umbral laxo en el que se espera un número elevado de falsos positivos; las propias listas contienen términos sin relación evidente con la neurobiología (p. ej., rutas oncológicas o de infección en el caso de MDD), lo que indica una contribución notable de ruido. En segundo lugar, los términos se reportan con p -valores nominales que no superan los umbrales de corrección por comparación múltiple (FDR), por lo que ninguno alcanza significación estadística formal. En tercer lugar, se empleó el universo de genes por defecto de Enrichr en lugar del panel de ~5 300 genes con modelo de expresión, lo que tiende a sobrestimar la significación. Por todo ello, las rutas comentadas a continuación, seleccionadas a posteriori por su coherencia biológica, deben interpretarse exclusivamente como hipótesis tentativas y no como conclusiones.

En el trastorno depresivo mayor, las vías más enriquecidas en la base de datos KEGG fueron la señalización de la insulina y la cascada mTOR. Ambas rutas tienen implicaciones directas en el metabolismo energético sináptico y en la plasticidad cortical. La vía mTOR, en particular, regula de

forma crítica la síntesis proteica postsináptica y la potenciación a largo plazo en la DLPFC; su perturbación es consistente con los déficits cognitivos y de plasticidad que caracterizan al trastorno depresivo mayor, y resulta especialmente relevante dado que la ketamina, el antidepresivo de acción más rápida disponible en la clínica actual, ejerce buena parte de su efecto terapéutico a través de la activación de esta ruta. Estos enriquecimientos, de carácter nominal y exploratorio (P nominal $\approx 0.01-0.02$), permiten formular una hipótesis a contrastar: que parte del riesgo genético heredable para la depresión en la DLPFC podría implicar circuitos de señalización metabólica y de síntesis proteica postsináptica. Dada la debilidad estadística de los términos y la heterogeneidad de la lista, esta interpretación no puede considerarse establecida.

En el trastorno bipolar, los enriquecimientos apuntan a una doble convergencia biológica. Por un lado, la biosíntesis de glucosaminoglicanos y glucoesfingolípidos sugiere una perturbación de la integridad estructural de la membrana neuronal; estos lípidos complejos son constituyentes esenciales de las balsas lipídicas (lipid rafts) en las que se anclan numerosos receptores de membrana y proteínas de señalización, de modo que su alteración podría comprometer la correcta propagación de señales neurales y la modulación de la neurotransmisión monoaminérgica. Conviene señalar, no obstante, que estas mismas rutas de glucoesfingolípidos (series ganglio y globo) figuran también entre los términos enriquecidos del fenotipo de tentativa de suicidio (Figura 27), por lo que su detección probablemente refleje en parte la composición del panel de expresión y un ruido compartido entre listas, más que un mecanismo específico del trastorno bipolar.

Por otro lado, el enriquecimiento en la regulación de la endocitosis de vesículas sinápticas y la respuesta a estímulos hormonales apunta a posibles disfunciones en el reciclaje de neurotransmisores y en la reactividad neuroendocrina del tejido prefrontal. Estos procesos son biológicamente coherentes con la oscilación ciclotímica y la hipersensibilidad a estresores que

caracterizan al fenotipo bipolar, y sugieren que el riesgo genético hereditario para este trastorno podría operar, en parte, a través de una alteración de la maquinaria de comunicación interneuronal en la DLPFC.

En la tentativa de suicidio, el enriquecimiento funcional detectó una señal de interés en la vía de la Anemia de Fanconi, un complejo multiproteico implicado en la reparación del daño al ADN por entrecruzamiento de cadenas. La sobrerrepresentación de esta ruta, junto con las vías del metabolismo de un solo carbono mediado por folato y los procesos de fusión autofagosoma-lisosoma, podría reflejar una vulnerabilidad celular al estrés genotóxico y un deterioro de los mecanismos de aclaramiento y homeostasis macromolecular. De particular relevancia es el metabolismo del folato, íntimamente ligado a la metilación del ADN y a la síntesis de monoaminas a través de la vía de la homocisteína, con amplia implicación en la neurobiología de la vulnerabilidad al suicidio documentada en la literatura. La implicación de vías autofágicas, por su parte, sugiere un posible deterioro en los mecanismos de aclaramiento de proteínas dañadas y orgánulos disfuncionales, consistente con los procesos de estrés celular crónico que se han asociado a la conducta suicida. No obstante, dado el carácter exploratorio del análisis y la ausencia de corrección por múltiple comparación estricta, estos enriquecimientos deben considerarse hipótesis biológicas a contrastar en estudios futuros, y no evidencias confirmatorias.

7.5. LIMITACIONES DEL ESTUDIO

Las conclusiones anteriores deben enmarcarse dentro de las limitaciones inherentes al presente trabajo. En primer lugar, el tamaño muestral moderado de las cohortes GWAS de origen (con una cantidad de casos de 325 (MDD), 527 (BD), 812 (SA) y un N total de alrededor de 4000-5000) restringe la potencia estadística e impide alcanzar la significación transcriptómica estricta. En segundo lugar, el análisis se limita a un único tejido cerebral —la DLPFC— lo que deja fuera de consideración la contribución de otras regiones con alta relevancia en la fisiopatología psiquiátrica,

como la amígdala o el hipocampo. En tercer lugar, el panel de referencia del CommonMind Consortium abarca únicamente los genes con modelos de expresión suficientemente heredables, lo que deja fuera del análisis una porción relevante del transcriptoma. En cuarto lugar, el análisis condicional permite priorizar estadísticamente candidatos funcionales, pero no establece causalidad biológica definitiva, para la cual sería imprescindible la validación experimental *in vitro* o *in vivo*. Finalmente, los análisis de enriquecimiento funcional se realizaron con *p*-valores nominales, sin alcanzar umbrales de FDR convencionales, por lo que los términos funcionales identificados tienen un carácter estrictamente exploratorio. Asimismo, el enriquecimiento funcional empleó el universo de genes por defecto de Enrichr en lugar del conjunto de genes con modelo de expresión disponible, lo que puede haber sobrestimado la significación de las vías identificadas.

7.6. CONCLUSIÓN GENERAL

El presente trabajo ha demostrado que la construcción e implementación de un pipeline TWAS riguroso sobre datos genómicos reales permite identificar candidatos transcriptómicos con plausibilidad neurobiológica en la DLPFC para el trastorno depresivo mayor, el trastorno bipolar y la tentativa de suicidio. Los genes sugestivos priorizados en cada fenotipo (tablas visibles en las páginas 61, 62 y 63) resultaron, en el análisis conjunto/condicional, señales transcripcionales independientes —sin falsos positivos por desequilibrio de ligamiento (Tabla 4)— y constituyen candidatos exploratorios para futuras investigaciones. Debe subrayarse que ninguno alcanza significación estadística tras la corrección por comparaciones múltiples, por lo que su priorización es orientativa y requiere validación en cohortes de mayor tamaño. El análisis de enriquecimiento funcional aporta hipótesis biológicas coherentes con la fisiopatología conocida de los tres trastornos, sugiriendo, de forma tentativa, la señalización mTOR en la depresión, la integridad de la membrana neuronal en el trastorno bipolar, y las rutas de reparación del ADN y autofagia en la conducta suicida como

territorios de exploración traslacional prometedores. En su conjunto, este trabajo avanza hacia la comprensión de la arquitectura funcional del riesgo genético psiquiátrico, situando al TWAS como un puente metodológico imprescindible entre la genómica descriptiva de los estudios GWAS y la neurobiología mecanicista que se requiere para el desarrollo futuro de biomarcadores de vulnerabilidad y dianas terapéuticas de precisión en psiquiatría.

8. PROSPECTIVA FUTURA

Los resultados obtenidos en el presente Trabajo de Fin de Grado establecen un marco computacional robusto para la priorización de genes candidatos en trastornos psiquiátricos, pero constituyen únicamente el primer eslabón en la cadena de inferencia causal. La naturaleza *in silico* de este estudio bioinformático abre de forma natural una serie de vías de investigación futuras, imprescindibles para trasladar estos hallazgos estadísticos hacia aplicaciones neurobiológicas y clínicas definitivas.

8.1. VALIDACIÓN EXPERIMENTAL FUNCIONAL (*IN VITRO* E *IN VIVO*)

La prioridad inmediata tras la identificación de candidatos transcripcionales independientes —como *PPM1J* y *RAB17* para el trastorno depresivo mayor, *LOC728323*, *PARK7*, *CRB1* y *SLMO1* para el trastorno bipolar, o *POLI*, *ANKRD18A* y *CD93* para la tentativa de suicidio— es su validación experimental. El análisis condicional confirmó que estos candidatos son señales independientes (no redundantes por LD); no obstante, su priorización es exploratoria: ninguno alcanza significación tras corrección y requiere validación experimental. Estudios futuros deberían emplear tecnologías de edición epigenética, como la interferencia o activación mediada por CRISPR (CRISPRi/CRISPRa), sobre modelos celulares derivados de células madre pluripotentes inducidas humanas (hiPSCs) u organoides cerebrales en 3D ([Cano-Gamez y Trynka, 2020](#)). La perturbación dirigida de la expresión

de estos genes permitirá evaluar alteraciones tangibles en la morfología dendrítica, la plasticidad sináptica o el metabolismo celular, confirmando empíricamente su papel causal en la patogénesis.

8.2. EXPANSIÓN DE LA RESOLUCIÓN ANATÓMICA Y UNICELULAR

Si bien en este trabajo se han logrado identificar candidatos transcripcionales independientes (no validados) en la corteza prefrontal dorsolateral (DLPFC) para la tentativa de suicidio, la compleja etiología de la conducta suicida y del resto de trastornos abordados sugiere que la varianza genética del riesgo está distribuida de forma pleiotrópica en múltiples estructuras cerebrales. Por tanto, es metodológicamente imperativo expandir los modelos predictivos TWAS hacia otras regiones del sistema límbico, como la amígdala, el hipocampo o el córtex cingulado anterior, las cuales gobiernan la reactividad emocional y la impulsividad.

Asimismo, el uso de datos de ARN provenientes de tejido homogeneizado (*bulk RNA*) promedia la señal de múltiples poblaciones celulares. La prospectiva metodológica del campo pasa por la transición hacia el TWAS de resolución unicelular (*single-cell TWAS* o *scTWAS*). La integración de los datos del GWAS con paneles de referencia transcriptómicos obtenidos mediante secuenciación de ARN de célula única (scRNA-seq) permitiría determinar si el riesgo genético opera específicamente a través de neuronas excitatorias glutamatérgicas, interneuronas inhibitoras GABAérgicas o poblaciones gliales, aportando un nivel de especificidad mecanística inalcanzable con los modelos actuales ([Skene et al., 2018](#)).

8.3. INTEGRACIÓN MULTI-ÓMICA A NIVEL DE SISTEMAS

La expresión génica es solo una capa de la maquinaria reguladora del genoma. Para obtener una visión holística de los tres fenotipos psiquiátricos, los hallazgos de este TWAS deben integrarse con otras dimensiones ómicas. La ejecución de estudios de asociación del proteoma completo (PWAS) ayudaría a confirmar si la alteración en los niveles de ARNm predicha se traduce

efectivamente en una modificación de la abundancia proteica. De igual manera, la integración con perfiles de metilación del ADN (MWAS) y estudios de splicing alternativo (sTWAS) permitiría reconstruir la cascada patogénica completa, desde la variante genética original, pasando por la regulación epigenética, hasta llegar a la traducción de las proteínas involucradas en las vías celulares alteradas (por ejemplo, las cascadas de la insulina y mTOR detectadas en el análisis de enriquecimiento) ([Wu et al., 2018](#)).

8.4. AUMENTO DE LA POTENCIA ESTADÍSTICA Y DIVERSIDAD ANCESTRAL

La limitación impuesta por el tamaño muestral moderado de las cohortes de origen ($N \approx 5000$) y el estricto control de Bonferroni invita a la reevaluación de este mismo pipeline bioinformático en el futuro próximo, a medida que los consorcios internacionales liberen macrocohortes clínicas integradas en biobancos masivos. Un mayor poder estadístico no solo permitiría que más *loci* cruzaran el umbral de significancia genómica estricta, sino que facilitaría el *fine-mapping* de variantes con tamaños de efecto infinitesimales. Paralelamente, es una necesidad clínica urgente diversificar los paneles de referencia de expresión. La dependencia actual de paneles mayoritariamente caucásicos (europeos) limita la extrapolación de los resultados; futuros análisis TWAS transancestrales serán vitales para definir qué arquitecturas de riesgo psiquiátrico son universales para la especie humana y cuáles son específicas de determinadas poblaciones ([Martin et al., 2019](#)).

8.5. TRASLACIÓN FARMACOGENÓMICA Y PSIQUIATRÍA DE PRECISIÓN

En última instancia, el horizonte de esta línea de investigación es el reposicionamiento de fármacos y la medicina de precisión. Las vías biológicas priorizadas mediante el análisis de sobrerrepresentación funcional (ORA) constituyen un mapa navegable para la intervención terapéutica. Por ejemplo, la validación de la vía mTOR en la arquitectura genética del MDD, la implicación del mantenimiento de la membrana lipídica en el BD, o las rutas de reparación del daño

al ADN y autofagia identificadas para la SA, abren la puerta al cribado bioinformático de moléculas ya aprobadas que actúen sobre estas cascadas ortólogas ([Gaspar y Breen, 2017](#)). Conectar las firmas de expresión genética de riesgo con perfiles transcriptómicos inversos de bases de datos farmacológicas (como Connectivity Map) representa el siguiente paso bioinformático natural para transformar estas predicciones en nuevas terapias diana.

BIBLIOGRAFÍA

Asociación Americana de Psiquiatría. (2023). *Manual diagnóstico y estadístico de los trastornos mentales* (5.^a ed., texto revisado). Editorial Médica Panamericana.

Anttila, V., Bulik-Sullivan, B., Finucane, H. K., Walters, R. K., Bras, J., Duncan, L., ... Neale, B. M. (2018). Analysis of shared heritability in common disorders of the brain. *Science*, 360(6395), eaap8757.

Bostwick, J. M., Pabbati, C., Geske, J. R., y McKean, A. J. (2016). Suicide attempt as a risk factor for completed suicide: Even more lethal than we knew. *American Journal of Psychiatry*, 173(11), 1094-1100.

Cano-Gamez, M., y Trynka, G. (2020). From GWAS to function: Using functional genomics to identify the mechanisms underlying complex diseases. *Frontiers in Genetics*, 11, Artículo 424. <https://doi.org/10.3389/fgene.2020.00424>

Chen, E. Y., Tan, C. M., Kou, Y., Duan, Q., Wang, Z., Meirelles, G. V., Clark, N. R., & Ma'ayan, A. (2013). Enrichr: Interactive and collaborative HTML5 gene list enrichment analysis tool. *BMC Bioinformatics*, 14, Article 128. <https://doi.org/10.1186/1471-2105-14-128>

Cross-Disorder Group of the Psychiatric Genomics Consortium. (2019). Genomic relationships, novel loci, and pleiotropic mechanisms across eight psychiatric disorders. *Cell*, 179(7), 1469-1482. <https://doi.org/10.1016/j.cell.2019.11.020>

Docherty, A. R., et al. (2023). GWAS meta-analysis of suicide attempt: Identification of 12 genome-wide significant loci and implication of genetic risks for specific health factors. *American Journal of Psychiatry*, 180(10), 723-738.

- Evans, P., Nagai, T., Konkashbaev, A., Zhou, D., Knapik, E. W., y Gamazon, E. R. (2024). Transcriptome-Wide Association Studies (TWAS): Methodologies, applications, and challenges. *Current Protocols*, 4(2), Artículo e981. <https://doi.org/10.1002/cpz1.981>
- Friedman, N. P., & Robbins, T. W. (2022). The role of prefrontal cortex in cognitive control and executive function. *Neuropsychopharmacology*, 47(1), 72–89. <https://doi.org/10.1038/s41386-021-01132-0>
- Fromer, M., Roussos, P., Sieberts, S. K., Johnson, J. S., Kavanagh, D. H., Perumal, T. M., ... Sklar, P. (2016). Gene expression elucidates functional impact of polygenic risk for schizophrenia. *Nature Neuroscience*, 19(11), 1442-1453. <https://doi.org/10.1038/nn.4399>
- Gallagher, M. D., y Chen-Plotkin, A. S. (2018). The post-GWAS era: From association to function. *American Journal of Human Genetics*, 102(5), 717-730. <https://doi.org/10.1016/j.ajhg.2018.04.002>
- Gandal, M. J., Haney, J. R., Parikshak, N. N., et al. (2018). Shared molecular neuropathology across major psychiatric disorders parallels polygenic overlap. *Science*, 359(6376), 693-697.
- Gandal, M. J., Zhang, P., Hadjimichael, E., Walker, R. L., Chen, C., Liu, S., Won, H., van Bakel, H., Varghese, M., Wang, Y., Shieh, A. W., Haney, J., Parhami, S., Belmont, J., Kim, M., Losada, P. M., Khan, Z., Mleczko, J., Xia, Y., ... Geschwind, D. H. (2018). Transcriptome-wide isoform-level dysregulation in ASD, schizophrenia, and bipolar disorder. *Science*, 362(6420), eaat8127. <https://doi.org/10.1126/science.aat8127>
- Gaspar, H. A., y Breen, G. (2017). Drug enrichment and discovery from schizophrenia genome-wide association results: An analysis and visualisation approach. *Scientific Reports*, 7(1), Artículo 12460. <https://doi.org/10.1038/s41598-017-12325-3>

Google. (2026). Gemini [Modelo de lenguaje de gran tamaño]. <https://gemini.google.com/>

Grande, I., Berk, M., Birmaher, B., y Vieta, E. (2016). Bipolar disorder. *The Lancet*, 387(10027), 1561-1572.

Gusev, A., Ko, A., Shi, H., Bhatia, G., Chung, W., Penninx, B. W., ... Pasaniuc, B. (2016). Integrative approaches for large-scale transcriptome-wide association studies. *Nature Genetics*, 48(3), 245-252. <https://doi.org/10.1038/ng.3506>

Howard, D. M., Adams, M. J., Clarke, T. K., et al. (2019). Genome-wide meta-analysis of depression identifies 102 independent variants and highlights the importance of the prefrontal brain regions. *Nature Neuroscience*, 22(3), 343-352.

Jollant, F., Lawrence, N. S., Olié, E., Guillaume, S., y Courtet, P. (2011). The suicidal mind and brain: A review of neuropsychological and neuroimaging studies. *The World Journal of Biological Psychiatry*, 12(5), 319-339.

Lu, Q., et al. (2023). Finding needles in the haystack: Strategies for uncovering noncoding regulatory variants. *Annual Review of Genetics*, 57, 1-24.

Mancuso, N., Freund, M. K., Johnson, R., Shi, H., Kichaev, G., Gusev, A., & Pasaniuc, B. (2019). Probabilistic fine-mapping of transcriptome-wide association studies. *Nature Genetics*, 51(4), 675–682

Martin, A. R., Kanai, M., Kamatani, Y., Okada, Y., Neale, B. M., y Daly, M. J. (2019). Clinical use of current polygenic risk scores may exacerbate health disparities. *Nature Genetics*, 51(4), 584-591. <https://doi.org/10.1038/s41588-019-0379-x>

Mullins, N., et al. (2022). Genome-wide association study of suicide attempt in psychiatric disorders identifies association with major depression polygenic risk scores. *American Journal of Psychiatry*, 179(3), 208-225.

Mullins, N., Forstner, A. J., O'Connell, K. S., et al. (2021). Genome-wide association study of more than 40,000 bipolar disorder cases provides new insights into the underlying biology. *Nature Genetics*, 53(6), 817-829.

O'Connell, K. S., Koromina, M., van der Veen, T., Boltz, T., David, F. S., Yang, J. M. K., Lin, K.-H., Wang, X., Coleman, J. R. I., Mitchell, B. L., McGrouther, C. C., Rangan, A. V., Lind, P. A., Koch, E., Harder, A., Parker, N., Bendl, J., Adorjan, K., Agerbo, E., ... Andreassen, O. A. (2025). Genomics yields biological and phenotypic insights into bipolar disorder. *Nature*, 639(8056), 968–975. <https://doi.org/10.1038/s41586-024-08468-9>

Okoro, P. C., Schubert, R., Guo, X., Johnson, W. C., Rotter, J. I., Hoeschele, I., Liu, Y., Im, H. K., Luke, A., y Dugas, L. R. (2021). Transcriptome prediction performance across machine learning models and diverse ancestries. *HGG Advances*, 2(2), Artículo 100019. <https://doi.org/10.1016/j.xhgg.2020.100019>

Organización Mundial de la Salud. (2019). *Mental disorders*.

Organización Mundial de la Salud. (2021). Suicide worldwide in 2019: Global health estimates.

Organización Mundial de la Salud. (2022). *Clasificación internacional de enfermedades para estadísticas de mortalidad y morbilidad* (11.^a ed.). <https://icd.who.int/es>

Organización Mundial de la Salud. (2023). *Depressive disorder (depression)*. <https://www.who.int/es/news-room/fact-sheets/detail/depression>

Otte, C., Gold, S. M., Penninx, B. W., Pariante, C. M., Etkin, A., Fava, M., ... Schatzberg, A. F. (2016). Major depressive disorder. *Nature Reviews Disease Primers*, 2(1), 1-20.

Reimand, J., Isserlin, R., Voisin, V., Kucera, M., Tannus-Lopes, C., Rostamianfar, A., Wadi, L., Meyer, M., Wong, J., Xu, C., Merico, D., & Bader, G. D. (2019). Pathway enrichment analysis... *Nature Protocols*, 14(2), 482–517

Skene, N. G., Bryois, J., Bakken, T. E., Breen, G., Crowley, J. J., Gaspar, H. A., ... y Hjerling-Leffler, J. (2018). Genetic identification of brain cell types underlying schizophrenia. *Nature Genetics*, 50(6), 825-833. <https://doi.org/10.1038/s41588-018-0129-5>

Smoller, J. W., Andreassen, O. A., Edenberg, H. J., Faraone, S. V., Glatt, S. J., y Kendler, K. S. (2019). Psychiatric genetics and the structure of psychopathology. *Molecular Psychiatry*, 24(3), 409-420.

Sokolowski, M., y Wasserman, D. (2021). The genetics of suicidal behavior. En *Psychiatric Genetics* (pp. 353-376). Springer.

Su, X., Chen, A., Teng, M., Ji, W., y Zhang, Y. (2023). Transcriptome-wide association study identifies new susceptibility genes and pathways for spondyloarthritis. *BMC Musculoskeletal Disorders*, 24(1), Artículo 430. <https://doi.org/10.1186/s12891-023-06541-1>

Toma, C., et al. (2026). *The Madrid Manic Group (MadManic) Cohort: Multi-Omics and Digital Phenotyping For the Studies of Severe Mental Disorders and Suicidality*. medRxiv. <https://www.medrxiv.org/content/10.64898/2026.04.14.26350865v1>

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267–288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>

Turecki, G., Brent, D. A., Gunnell, D., O'Connor, R. C., Oquendo, M. A., Pirkis, J., y Stanley, B. H. (2019). Suicide and suicide risk. *Nature Reviews Disease Primers*, 5(1), 74. <https://doi.org/10.1038/s41572-019-0121-0>

Wainberg, M., Sinnott-Armstrong, N., Mancuso, N., Barbeira, A. N., Knowles, D. A., Golan, D., ... Kundaje, A. (2019). Opportunities and challenges for transcriptome-wide association studies. *Nature Genetics*, 51(4), 592-599.

Wray, N. R., Ripke, S., Mattheisen, M., Trzaskowski, M., Byrne, E. M., Abdellaoui, A., ... y Sullivan, P. F. (2018). Genome-wide association analyses identify 44 risk variants and refine the genetic architecture of major depression. *Nature Genetics*, 50(5), 668-681.

Wu, L., Shi, W., Long, J., Guo, X., Michailidou, K., Beesley, J., ... y Zheng, W. (2018). A transcriptome-wide association study of 229,000 women identifies new candidate susceptibility genes for breast cancer. *Nature Genetics*, 50(7), 968-978. <https://doi.org/10.1038/s41588-018-0132-x>

Zou, H., y Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 67(2), 301-320. <https://doi.org/10.1111/j.1467-9868.2005.00503.x>

ANEXOS

9. ANEXO I. PROTOCOLOS COMPUTACIONALES Y SCRIPTS DE PROCESAMIENTO DE DATOS EN R

9.1. CÓDIGO I.1. PREPROCESAMIENTO DE ESTADÍSTICAS DE RESUMEN Y CÁLCULO DE Z-SCORES

```
limpiar_daner.R
cat("Leyendo el archivo...\n")

datos <- read.table("daner_MadManic_BD_020226.sumstats", header=TRUE,
stringsAsFactors=FALSE)

# 1. Limpieza matemática básica (Eliminar NAs y ORs inválidos)
datos_limpios <- subset(datos, !is.na(OR) & !is.na(SE) & OR > 0)

# 2. Calculamos el Z-score directamente sobre los datos limpios
datos_limpios$Z <- log(datos_limpios$OR) / datos_limpios$SE

# 3. Preparamos el input final para FUSION
fusion_input <- datos_limpios[, c("SNP", "A1", "A2", "Z")]

# 4. Guardamos el archivo definitivo
write.table(fusion_input, "sumstats_BD_FUSION_FINAL.txt", sep="\t",
row.names=FALSE, quote=FALSE)

cat("Proceso terminado de control de calidad. Archivo creado con éxito.\n")
```

9.2. CÓDIGO I.2. PROCESAMIENTO ESTADÍSTICO POST-TWAS, AJUSTE POR COMPARACIONES MÚLTIPLES Y GENERACIÓN DE MANHATTAN PLOT

```
# =====
# SCRIPT COMPLETO: TWAS SA
# =====

# 0. Cargar la librería necesaria para el gráfico
```

```
library(qqman)

cat("Leyendo los resultados completos del TWAS de tentativa de suicidio...\n")

# 1. Cargamos el archivo maestro

twas_data <- read.table("RESULTADOS_TWAS_SA_COMPLETOS.txt", header=TRUE,
stringsAsFactors=FALSE)

# --- AJUSTES ESTADÍSTICOS (Rigor TFG) ---

cat("Calculando ajustes estadísticos (FDR y Bonferroni)...\n")

# Hay que asegurarse de que el p-valor es numérico antes de calcular

twas_data$TWAS.P <- as.numeric(twas_data$TWAS.P)

twas_data$P_FDR <- p.adjust(twas_data$TWAS.P, method = "fdr")
twas_data$P_Bonferroni <- p.adjust(twas_data$TWAS.P, method = "bonferroni")
# -----

cat("Extrayendo los genes más interesantes...\n")

# 2. Se filtra la tabla original (P < 0.001)

top_genes <- twas_data[!is.na(twas_data$TWAS.P) & twas_data$TWAS.P < 0.001, ]

# 3. Ordenación jerárquica por significación estadística

top_genes <- top_genes[order(top_genes$TWAS.P), ]

# 4. Se guarda la tabla con todos los datos (incluyendo FDR) en CSV

write.csv(top_genes, "Top_Genes_Suicidio.csv", row.names = FALSE)

cat(";Tabla Top_Genes_Suicidio.csv guardada!\n")

# 5. Preparamos los datos para el gráfico

cat("Preparando datos para el gráfico...\n")

plot_data <- twas_data
plot_data$SNP <- plot_data$ID
plot_data$CHR <- as.numeric(plot_data$CHR)
plot_data$BP <- as.numeric(plot_data$P0)
plot_data$P <- as.numeric(plot_data$TWAS.P)
```

```
# Limpiamos posibles NAs que rompan el gráfico
plot_data <- na.omit(plot_data[, c("SNP", "CHR", "BP", "P")])

# 6. Generación del Manhattan plot con etiquetado dinámico y ALTA RESOLUCIÓN
cat("Creando el gráfico Manhattan de tentativa de suicidio (Alta Calidad)...\n")

# Aumento de resolución a 300 ppi (calidad TFG/Publicación)
png("Manhattan_TWAS_SA_Etiquetado.png", width=3600, height=1800, res=300)

manhattan(plot_data,
           chr = "CHR", bp = "BP", snp = "SNP", p = "P",
           main = "TWAS: Tentativa de suicidio y expresión en corteza prefrontal
dorsolateral",
           xlab = "Cromosoma",
           ylab = expression("-log"[10]"(p-valor)"),           # Subíndice
matemático profesional
           col = c("royalblue4", "deepskyblue"),
           suggestiveline = -log10(1e-3),           # Línea azul para el umbral
sugestivo
           genomewideline = FALSE,           # Omisión de línea Bonferroni
estricta
           annotatePval = 1e-3,           # Etiquetado automático de loci
sugerentes
           annotateTop = FALSE,
           cex = 0.85,           # Tamaño de los puntos
           cex.axis = 1.1,           # Tamaño de los números de los
ejes
           cex.lab = 1.3,           # Tamaño de las etiquetas de
ejes
           cex.main = 1.5)           # Tamaño del título principal

dev.off()

cat(";Nuevo gráfico Manhattan_TWAS_SA_Etiquetado.png guardado con éxito!\n")
```

9.3. CÓDIGO I.3. FILTRADO Y SANITIZACIÓN DE DATOS PARA ANÁLISIS CONDICIONAL. EJEMPLO DE FILTRADO_CONDICIONAL_MDD

```
cat("Iniciando protocolo de limpieza...\n")

# 1. Carga de los resultados completos del TWAS
twas_data <- read.table("RESULTADOS_TWAS_MDD_COMPLETOS.txt", header=TRUE,
stringsAsFactors=FALSE)

# 2. Coerción numérica para eliminación de artefactos "NA" textuales
twas_data$CHR <- as.numeric(twas_data$CHR)
twas_data$TWAS.P <- as.numeric(twas_data$TWAS.P)

# 3. Eliminación de filas con valores nulos computables
datos_limpios <- twas_data[!is.na(twas_data$CHR) & !is.na(twas_data$TWAS.P), ]

# 4. Filtrado de genes sugestivos (P < 0.001) para input condicional
datos_finales <- datos_limpios[datos_limpios$TWAS.P < 0.001, ]

# 5. Exportación del conjunto de datos limpio
write.table(datos_finales, "INPUT_CONDICIONAL_MDD_LIMPIO.txt", quote=FALSE,
row.names=FALSE, sep="\t")

cat("Limpieza terminada. Se han extraído", nrow(datos_finales), "genes
limpios.\n")
```

9.4. CÓDIGO I.4. EXTRACCIÓN DE *LOC*/ CANDIDATOS PARA ANÁLISIS DE ENRIQUECIMIENTO FUNCIONAL. EJEMPLO LIMPIAR_RESULTADOS_ENRIQUECIMIENTO_BD.R

```
cat("Iniciando extracción de genes para Pathway Analysis...\n")

# 1. Se carga el archivo maestro
datos <- read.table("RESULTADOS_TWAS_BD_COMPLETOS.txt", header=TRUE,
stringsAsFactors=FALSE)

# 2. Conviene asegurarse de que el p-valor es numérico y se eliminen los NAs
datos$TWAS.P <- as.numeric(datos$TWAS.P)
```

```
datos_limpios <- datos[!is.na(datos$TWAS.P), ]

# 3. Se aplica el umbral (en este caso, 0.05)
genes_filtrados <- datos_limpios[datos_limpios$TWAS.P < 0.05, ]

# 4. Se extrae unicamente la columna ID de los genes
lista_genes <- genes_filtrados$ID

# 5. Se guarda la lista limpia en un nuevo archivo de texto
write.table(lista_genes, "Lista_Enrichr_BD_005.txt", quote=FALSE,
row.names=FALSE, col.names=FALSE)

cat("Extracción completada. Hay una lista de", length(lista_genes), "genes para
incluir en Enrichr.\n")
```

Declaración de uso de inteligencia artificial generativa

Durante la elaboración de este Trabajo Fin de Grado se ha empleado Gemini, modelo de inteligencia artificial generativa desarrollado por Google, de forma puntual y exclusivamente con fines auxiliares. Su uso se ha limitado a la revisión de estilo, la corrección ortotipográfica y el apoyo en la mejora de la fluidez y la claridad expositiva de fragmentos específicos. La herramienta no ha generado contenido original, ni se ha utilizado como fuente de información científica o sustituto del análisis riguroso propio.